

Introdução à Mineração de Dados

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Por que Mineração de Dados?

O Cenário do Big Data

Vivemos em uma era de **crescimento explosivo de dados**, passando de terabytes para petabytes em poucos anos. Ferramentas automatizadas de coleta, sistemas de banco de dados e a Web transformaram a maneira como armazenamos informações.

Principais Fontes de Dados

- **Negócios:** Web, e-commerce, transações financeiras
- **Ciência:** Sensores, astronomia, bioinformática, simulações
- **Sociedade:** Notícias, fotos, vídeos, dados abertos, IoT

❏ **"Estamos nos afogando em dados, mas morrendo de sede por conhecimento!"**

A necessidade é a mãe da invenção — a mineração de dados surgiu como resposta à análise automatizada de conjuntos massivos de dados.



O que é Mineração de Dados?

Descoberta de Conhecimento em Dados


A mineração de dados (ou *knowledge discovery from data*) é a **extração de padrões interessantes ou conhecimento** a partir de quantidades massivas de dados.

Características dos Padrões

- **Não triviais:** Não óbvios à primeira vista
- **Implícitos:** Ocultos nos dados
- **Previamente desconhecidos:** Não armazenados explicitamente
- **Potencialmente úteis:** Acionáveis para tomada de decisão

Nomes Alternativos

- Knowledge Discovery in Databases (KDD)
- Knowledge Extraction
- Business Intelligence
- Data Analysis



O Processo KDD

O processo de Descoberta de Conhecimento em Bases de Dados (KDD) representa uma visão clássica de sistemas de banco de dados. A mineração de dados desempenha um **papel essencial** neste processo, mas é apenas uma das etapas de uma jornada maior.




Cada etapa é crucial para garantir que o conhecimento extraído seja válido, confiável e útil para a tomada de decisões estratégicas.

Visão Geral do CRISP-DM

Cross-Industry Standard Process for Data Mining é uma metodologia amplamente utilizada e padronizada pela indústria para projetos estruturados de mineração de dados.

Diferentemente de abordagens lineares, o CRISP-DM é **cíclico e iterativo**, reconhecendo que projetos de dados raramente seguem um caminho direto do início ao fim.



KDD vs. CRISP-DM: Comparação

Embora o KDD e o CRISP-DM compartilhem objetivos semelhantes, suas abordagens e origens diferem significativamente. O **KDD** é o processo conceitual mais amplo de descoberta de conhecimento em dados, enquanto o **CRISP-DM** fornece um guia prático e cíclico para gerenciar projetos de mineração de dados em ambientes reais.

KDD

- Origem **acadêmica**
- Processo **linear**
- Ênfase na **extração de conhecimento**
- Abordagem mais teórica
- Foco em algoritmos e técnicas

CRISP-DM

- Origem **industrial**
- Processo **cíclico**
- Ênfase na **resolução de problemas de negócio**
- Abordagem mais prática
- Foco em entregas e resultados

Característica	KDD	CRISP-DM
Origem	Academia	Indústria
Processo	Linear	Cíclico
Ênfase	Extração de Conhecimento	Solução de Problemas de Negócio
Aplicação	Pesquisa e Desenvolvimento	Projetos Empresariais

Enquanto o KDD é mais acadêmico e linear, o CRISP-DM é iterativo e fundamentado em aplicações do mundo real.

Tudo é "Mineração de Dados"?

Não!

É importante distinguir a mineração de dados de outras atividades relacionadas ao processamento de informações. Embora essas áreas se sobreponham na prática, cada uma possui características e objetivos distintos.

Consultas (Queries)

Recuperação de dados específicos usando linguagens como SQL. As consultas retornam informações conhecidas e explícitas, não descobrem padrões ocultos.

Relatórios (Reporting)

Apresentação estruturada de dados agregados e métricas. Os relatórios resumem informações existentes, mas não identificam novos insights automaticamente.

Estatística Tradicional

Análise de dados usando métodos estatísticos clássicos. Focada em testes de hipóteses pré-definidas, enquanto mineração de dados busca padrões sem hipóteses iniciais.


Mineração de Dados

Descoberta automática de padrões não triviais, implícitos e potencialmente úteis em grandes volumes de dados, usando algoritmos avançados de aprendizado.

- ❑ A mineração de dados se distingue por sua capacidade de descobrir conhecimento novo e acionável sem orientação explícita sobre o que procurar.

Visão Multidimensional da Mineração de Dados

A mineração de dados pode ser compreendida através de múltiplas dimensões que definem seu escopo e aplicabilidade. Esta visão multidimensional ajuda a categorizar e entender a amplitude da área.



Mineração em Dados Orientados a Bancos de Dados

A mineração de dados começou com estruturas tradicionais de banco de dados e continua sendo fundamental em muitas aplicações empresariais. Esses conjuntos de dados são caracterizados por sua **estrutura bem definida** e relações claras entre entidades.

Bancos de Dados Relacionais

Estruturas tabulares com esquemas definidos, chaves primárias e estrangeiras. Permitem consultas SQL e suportam transações ACID.

Bancos Transacionais

Sistemas OLTP focados em processamento rápido de transações. Capturam eventos de negócio em tempo real com alta concorrência.

Bancos Heterogêneos

Integração de múltiplos sistemas de banco de dados diferentes. Requerem técnicas especiais de integração e limpeza.

Data Warehouses

Repositórios centralizados otimizados para análise e relatórios. Integram dados de múltiplas fontes com esquemas dimensionais (estrela/floco de neve).

Bancos Objeto-Relacionais

Combinam características relacionais com orientação a objetos. Suportam tipos de dados complexos e herança.

Sistemas Legados

Bancos de dados antigos ainda em operação. Apresentam desafios de compatibilidade e modernização.

Mineração em Conjuntos de Dados Avançados

À medida que a tecnologia evolui, novos tipos de dados emergem, exigindo técnicas especializadas de mineração. Esses **dados avançados** apresentam características únicas que desafiam métodos tradicionais.

Dados de Streaming e Sensores

Fluxos contínuos de dados em tempo real que requerem processamento imediato

Séries Temporais

Dados ordenados no tempo com dependências sequenciais e tendências

Grafos e Redes Sociais

Estruturas complexas de nós e conexões representando relacionamentos

Dados Espaciais e Espaço-Temporais

Informações georreferenciadas com dimensões de localização e tempo

Bancos Multimídia

Imagens, vídeos, áudio requerendo análise de conteúdo não estruturado

Bases Textuais

Documentos, artigos, posts processados por text mining e NLP

World Wide Web

Dados semi-estruturados com hiperlinks, tags e metadados

Sequências Biológicas

DNA, proteínas e dados genômicos com padrões complexos

Cada tipo de dado avançado requer algoritmos especializados, técnicas de pré-processamento únicas e considerações especiais de escalabilidade. A mineração eficaz desses dados é crucial para aplicações modernas em IoT, bioinformática, análise de redes sociais e muito mais.

Função de Mineração de Dados: Generalização

Resumindo e Abstraindo Dados

A **generalização** é o processo de abstrair dados detalhados em representações de nível superior que facilitam a compreensão e análise. Esta função é fundamental para data warehousing e análise OLAP.

Componentes Principais

- **Integração de Informações:** Consolidação de múltiplas fontes de dados
- **Data Warehouse:** Repositórios otimizados para consultas analíticas
- **Limpeza e Transformação:** Preparação e padronização dos dados
- **Modelo Multidimensional:** Organização em cubos de dados com dimensões e medidas

Tecnologia de Cubo de Dados

Métodos escaláveis para computar e materializar agregações multidimensionais, permitindo análises rápidas em diferentes níveis de granularidade.

OLAP (Online Analytical Processing)

Ferramentas interativas para exploração multidimensional de dados, incluindo operações de drill-down, roll-up, slice e dice.

Descrição Conceitual Multidimensional

Caracterização e discriminação de dados. Por exemplo, generalizar medidas de pluviometria em categorias como "região seca" vs. "região úmida".

❏ A generalização permite que analistas vejam o "panorama geral" antes de mergulhar em detalhes específicos, facilitando a descoberta de tendências e padrões macro.

Função de Mineração: Associação e Correlação

Descobrendo Relacionamentos em Dados

A análise de **associação e correlação** identifica relacionamentos interessantes entre itens em grandes conjuntos de dados transacionais.

Conceitos Fundamentais

- **Padrões Frequentes (Itemsets):** Conjuntos de itens que aparecem juntos com frequência
- **Regras de Associação:** Implicações do tipo "Se X, então Y"
- **Suporte:** Frequência de ocorrência do padrão
- **Confiança:** Probabilidade condicional da regra

Exemplo Clássico

Fraldas $\square$ Cerveja [0.5%, 75%]

Esta regra indica que 0.5% das transações contêm ambos os itens (suporte), e 75% das compras de fraldas incluem cerveja (confiança).

Associação vs. Correlação vs. Causalidade

Itens fortemente associados nem sempre são correlacionados. É crucial distinguir entre correlação estatística e causalidade real.

Questões Principais

1. Como minerar tais padrões e identificar regras eficientemente em grandes datasets?
2. Como usar e rankear esses padrões para tomada de decisão?
3. Quais medidas além de suporte e confiança são relevantes?

Aplicações incluem análise de cestas de compras, recomendação de produtos, detecção de fraudes e análise de clickstream em websites.

Função de Mineração: Previsão

Classificação e Predição de Rótulos

A **previsão** envolve construir modelos baseados em exemplos de treinamento para prever valores futuros ou classificar novos dados. Esses modelos são *data-driven*, aprendendo padrões diretamente dos dados.

O processo típico inclui:

1. Coletar dados de treinamento rotulados
2. Extrair características relevantes
3. Treinar modelo usando algoritmo de aprendizado
4. Avaliar desempenho em dados de teste
5. Aplicar modelo para predições em novos dados

Métodos Típicos

- Árvores de Decisão
- Naive Bayes
- Máquinas de Vetores de Suporte (SVM)
- Redes Neurais e Deep Learning
- Random Forest
- Regressão Linear/Logística
- CNNs, RNNs, Transformers

Aplicações Típicas

- **Científicas:** Previsão climática, análise genômica
- **Industriais:** Manutenção preditiva, controle de qualidade
- **Empresariais:** Churn prediction, detecção de fraudes
- **Governamentais:** Análise de crédito, segurança pública

Função de Mineração: Análise de Clusters

Aprendizado Não Supervisionado

A **análise de clusters** é uma técnica de aprendizado não supervisionado onde os rótulos de classe são desconhecidos. O objetivo é agrupar dados para formar novas categorias baseadas em similaridade.

Princípio Fundamental

Maximizar a similaridade intra-classe e **minimizar a similaridade inter-classes**. Objetos dentro do mesmo cluster devem ser similares, enquanto objetos de clusters diferentes devem ser distintos.

Aplicações Práticas

- Segmentação de clientes
- Análise de padrões de compra
- Agrupamento de documentos
- Identificação de comunidades em redes sociais
- Análise de imagens e padrões visuais

Métodos de Particionamento

K-means, K-medoids: dividem dados em k grupos distintos

Métodos Hierárquicos

Agglomerative, Divisive: criam árvores de clusters

Métodos Baseados em Densidade

DBSCAN: identificam clusters de formas arbitrárias

☐ Diferentemente da classificação, o clustering não requer dados de treinamento rotulados, tornando-o ideal para descoberta exploratória de padrões em dados desconhecidos.

Função de Mineração: Análise de Outliers



Um **outlier** é um objeto de dados que não está em conformidade com o comportamento geral dos dados. A questão fundamental é: trata-se de ruído ou exceção? O "lixo" de uma pessoa pode ser o "tesouro" de outra.

Abordagens de Detecção

Estatística: Baseada em distribuições probabilísticas e desvios padrão

Clustering: Pontos que não pertencem a nenhum cluster ou formam clusters muito pequenos

Análise de Regressão: Pontos que se desviam significativamente do modelo ajustado




Aplicações Valiosas

Detecção de Fraudes: Transações financeiras anômalas

Análise de Eventos Raros: Falhas em sistemas, doenças raras

Controle de Qualidade: Produtos defeituosos em manufatura



A detecção de outliers é crucial em muitos domínios, pois anomalias frequentemente indicam eventos importantes, erros críticos ou oportunidades valiosas que merecem investigação especial.


Função de Mineração: Detecção de Eventos

A **detecção de eventos** em séries temporais identifica ocorrências significativas que desviam do comportamento esperado ou padrões recorrentes de interesse.

Anomalias

Padrões ou observações que não se conformam ao comportamento esperado. Podem ser baseados em distribuição, distância de um modelo ou volatilidade. Construídos a partir de processos distintos dos dados normais.


Anomalia



Motifs

Padrões (inicialmente desconhecidos) que ocorrem um número significativo de vezes em um dataset. Representam estruturas repetitivas que caracterizam o comportamento típico dos dados.


Motif



Change Points / Concept Drifts

Pontos ou intervalos de tempo que marcam mudanças significativas no comportamento do dataset. Separam diferentes estados no processo que gera os dados.

Change Point



A detecção de eventos é fundamental para monitoramento de sistemas, análise de mercados financeiros, previsão de falhas em equipamentos e compreensão de mudanças em processos complexos.

Função de Mineração: Padrões Sequenciais

Mineração de Padrões Sequenciais

A **mineração de padrões sequenciais** detecta e analisa subsequências frequentes de eventos, itens ou tokens que ocorrem em um espaço métrico ordenado.

Diferentemente da análise de associação, que ignora ordem, a mineração sequencial considera a **ordem temporal ou posicional** dos elementos.

Características Principais

- Elementos ordenados no tempo ou espaço
- Subsequências que ocorrem frequentemente
- Padrões podem ter gaps (não necessariamente consecutivos)
- Considera restrições temporais entre eventos

Análise de Clickstream

Padrões de navegação em websites

Comportamento de Compra

Sequências de produtos comprados ao longo do tempo

Análise de DNA

Subsequências genéticas frequentes

Padrões Sazonais

Eventos que se repetem em ciclos temporais

Exemplo: *Compra notebook → 2 semanas → Compra mouse → 1 mês → Compra impressora* representa um padrão sequencial de compras relacionadas a computadores.

Função de Mineração: Análise de Estruturas e Redes

Mineração de Estruturas e Redes


A análise de estruturas e redes explora dados que possuem **relacionamentos complexos** representados como grafos, árvores ou outras estruturas interconectadas.

Mineração de Estruturas

Extraí padrões de dados estruturados como árvores XML, grafos moleculares e layouts de páginas web. Aplicações incluem bioinformática, química e análise de documentos.

Análise de Redes

Minera nós e arestas em redes como sociais, de citações e comunicação. Tarefas incluem detecção de comunidades, centralidade, influência e predição de links.




Detecção de Comunidades Web

Identificar grupos de páginas ou usuários com interesses similares e forte conectividade interna.



Proteínas Similares em Redes Biológicas

Encontrar proteínas com estruturas ou funções semelhantes baseadas em interações moleculares.



Descoberta de Influenciadores em Redes Sociais

Identificar usuários com maior alcance, engajamento e capacidade de disseminar informação.

Métricas de Centralidade

Degree, Betweenness, Closeness, PageRank

Algoritmos de Comunidade


Louvain, Label Propagation, Modularity

Análise de Difusão

Propagação de informação, epidemias, cascatas

Natureza Multidisciplinar da Mineração de Dados

A mineração de dados atua como ponto de convergência entre diversas áreas do conhecimento — cada uma contribuindo com perspectivas únicas e ferramentas essenciais para o processo de descoberta de conhecimento.



Por Que Tantas Disciplinas?

Volume Tremendo de Dados

A explosão de dados gerados por sistemas digitais, sensores e interações humanas exige técnicas escaláveis que vão além das abordagens estatísticas tradicionais.

Complexidade Elevada

Dados reais são ruidosos, incompletos e heterogêneos, exigindo integração de múltiplas abordagens para lidar com incerteza e variabilidade.

Alta Dimensionalidade

Conjuntos de dados modernos possuem centenas ou milhares de variáveis, demandando métodos especializados para seleção de atributos e redução de dimensionalidade.

Aplicações Sofisticadas

Domínios como saúde, finanças e engenharia requerem conhecimento especializado combinado com técnicas computacionais avançadas para gerar insights acionáveis.

Principais Desafios na Mineração de Dados

O campo da mineração de dados enfrenta desafios significativos que vão muito além da simples aplicação de algoritmos. Estes desafios refletem tanto limitações técnicas quanto preocupações sociais crescentes sobre o uso responsável de dados.

Metodologia e Interação

- Mineração em espaços multidimensionais
- Descoberta de conhecimento em múltiplos níveis de abstração
- Incorporação de conhecimento de domínio
- Mineração interativa e exploratória

Desempenho e Escalabilidade

- Eficiência e escalabilidade de algoritmos
- Mineração paralela, distribuída e incremental
- Otimização para hardware moderno

Diversidade de Tipos de Dados

- Dados estruturados, semi-estruturados e não estruturados
- Dados complexos: grafos, sequências, dados espaciais
- Multimídia e fluxos de dados em tempo real

Mineração de Dados e Sociedade

- Propriedade e privacidade dos dados
- Segurança e sensibilidade das informações
- Questões éticas e impacto social
- Mineração responsável e justa
- Interpretabilidade dos modelos

Disponibilidade e Acesso aos Dados

Antes de iniciar qualquer projeto de mineração de dados, questões fundamentais sobre acesso e uso dos dados devem ser cuidadosamente consideradas — envolvendo aspectos legais, éticos e práticos que podem determinar a viabilidade do projeto.

- **Você tem acesso aos dados?** Disponibilidade física e permissões necessárias
- **Você pode usar os dados?** Aspectos legais e contratuais
- **Você pode publicar seus resultados?** Propriedade intelectual e confidencialidade
- **É big data ou small data?** Volume suficiente para justificar mineração de dados?

❏ Small data pode ser extremamente valioso. A distinção entre big e small data não é apenas sobre volume, mas sobre a relevância e qualidade da informação disponível.

Data Mining, Data Science e Analytics

A mineração de dados existe dentro de um ecossistema mais amplo de disciplinas relacionadas. Compreender as distinções e conexões entre data mining, data science e analytics é fundamental para posicionar adequadamente o trabalho de pesquisa e prática profissional.

Data Science: Visão Disciplinar

Data Science é um campo interdisciplinar emergente que sintetiza e se baseia em Estatística, Ciência da Computação, Comunicação, Gestão e Sociologia para estudar dados e seus ambientes (incluindo aspectos de domínio e contextuais) de forma a transformar dados em conhecimento e decisões.

Mineração de Dados como Núcleo

- **Data Mining:** Algoritmos e modelos para descoberta de padrões
- **Data Science:** Dados + contexto + tomada de decisão
- Áreas complementares, não concorrentes

Analytics Descritiva

Usa estatísticas para descrever e sumarizar os dados analisados, revelando o que aconteceu.

Analytics Preditiva

Faz previsões sobre eventos futuros desconhecidos através de análise avançada, revelando por que algo aconteceu.

Analytics Prescritiva

Otimiza recomendações e sugere ações para tomada de decisões inteligentes.

Referências: [1] V. Dhar, 2013, "Data science and prediction", Communications of the ACM, v. 56, n. 12, p. 64–73. [2] L. Cao, 2017, "Data science: Challenges and directions", Communications of the ACM, v. 60, n. 8, p. 59–68.

Onde Publicar sua Pesquisa?

A escolha adequada de veículos de publicação é crucial para disseminar pesquisas e construir uma carreira acadêmica sólida. O ecossistema de publicações em mineração de dados é rico e diversificado, abrangendo conferências de prestígio e periódicos de alto impacto.

Data Mining, KDD e Data Science

Conferências: SIGKDD, IEEE-ICDM, SIAM-DM, PKDD, IEEE-DSAA

Periódicos: Data Mining and Knowledge Discovery, Statistical Analysis and Data Mining, ACM Transactions on Knowledge Discovery from Data

Sistemas de Banco de Dados

Conferências: SIGMOD, PODS, VLDB, IEEE-ICDE, EDBT, ICDT, SSDDBM

Periódicos: IEEE-TKDE, VLDB Journal, Information Systems

IA e Aprendizado de Máquina

Conferências: AAAI, ML, IJCNN, IJCAI, NeurIPS

Periódicos: Machine Learning, Artificial Intelligence, Knowledge and Information Systems

Estatística

Periódicos: Journal of Applied Statistics, Annals of Data Science

Aplicações Específicas

Periódicos: Diversos periódicos especializados por domínio de aplicação

Linguagens em Alta para Data Mining

A escolha da linguagem de programação impacta significativamente a produtividade e as possibilidades de implementação em projetos de mineração de dados. Três ecossistemas dominam o cenário atual, cada um com suas forças particulares.

Python

Machine Learning Course

- Scikit-learn: biblioteca completa para ML clássico
- PyTorch: framework para deep learning
- TensorFlow: plataforma end-to-end para ML

Ecossistema rico, comunidade ativa, ideal para prototipagem rápida e produção.

R

Data Mining Course

- Miríade de pacotes especializados
- Forte orientação estatística
- Excelente para análise exploratória

Linguagem de escolha para estatísticos e cientistas de dados focados em análise.

Spark

Parallel and Distributed Computing

- MLlib: biblioteca de ML escalável
- Processamento distribuído
- Ideal para big data

Solução empresarial para processar volumes massivos de dados em clusters.

Ferramentas de Data Mining

Ferramentas de mineração de dados com interface gráfica democratizam o acesso a técnicas sofisticadas, permitindo que profissionais de diversas áreas apliquem algoritmos avançados sem programação extensiva. O ecossistema open source oferece opções robustas e profissionais.

RapidMiner

Plataforma visual para ciência de dados com interface intuitiva de arrastar e soltar. Suporta todo o ciclo de vida de ML.

rapidminer.com

Weka

Coleção clássica de algoritmos de ML para tarefas de mineração de dados. Interface Java robusta e extensível.

cs.waikato.ac.nz/ml/weka

Apache Mahout

Biblioteca escalável de ML construída sobre Hadoop e Spark. Focada em recomendações, classificação e clustering.

mahout.apache.org

Orange

Ferramenta de visualização e análise de dados com widgets interativos. Excelente para ensino e exploração.

orange.biolab.si

KNIME

Plataforma modular para análise de dados com extenso repositório de componentes. Integração com R e Python.

knime.com

Rattle

Interface gráfica para R, simplificando o acesso às poderosas capacidades estatísticas da linguagem.

rattle.togaware.com



Referências Principais

Esta seleção de referências representa os pilares fundamentais para o estudo aprofundado de mineração de dados, cobrindo desde conceitos básicos até técnicas avançadas e aplicações contemporâneas.

