



Visualização de Dados

Uma exploração abrangente das técnicas e ferramentas modernas para criar visualizações de dados impactantes e eficazes usando R e ggplot2.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Plotando Gráficos com R

Funções Básicas do R

O R vem com funções de plotagem básicas que são fáceis de operar para gráficos simples, mas apresentam limitações significativas quando se trata de visualizações mais complexas e personalizadas.

ggplot2: Uma Revolução em Gráficos

O ggplot2 é um sistema para criar gráficos de forma declarativa, baseado na Grammar of Graphics. Ele oferece flexibilidade excepcional e permite construir visualizações sofisticadas de maneira intuitiva.


- ❏ A maneira mais fácil de obter o ggplot2 é instalar todo o tidyverse:

```
install.packages("tidyverse")
```

```
install.packages("ggplot2")
```

Exemplos de Gráficos com ggplot2

Esta galeria demonstra a ampla variedade de visualizações que você pode criar usando ggplot2. É um recurso excepcional para inspiração e aprendizado sobre como personalizar seus gráficos de acordo com suas necessidades específicas.



Explore a galeria completa: r-graph-gallery.com/ggplot2-package

DAL Toolbox: Encapsulamento do ggplot2

O DAL Toolbox facilita a criação de gráficos encapsulando o ggplot2, permitindo um início mais simples enquanto você aprende a usar essa poderosa ferramenta de visualização.

Parâmetro X

Associado ao eixo x — representa a variável independente

Parâmetro Value

Relacionado ao eixo y — representa os valores a serem plotados

Parâmetro Group

Parâmetro opcional que define variáveis de agrupamento para categorização

Dataset Iris — Exemplo Clássico

```
head(iris, 3)
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1      5.1      3.5      1.4      0.2 setosa
## 2      4.9      3.0      1.4      0.2 setosa
## 3      4.7      3.2      1.3      0.2 setosa
```

❏ Carregue as bibliotecas necessárias:

```
library(daltoolbox)
library(ggplot2)
```

Documentação completa: github.com/cefet-rj-dal/daltoolbox/graphics

Configuração de opções gráficas:

```
colors <- brewer.pal(4, 'Set1')
font <- theme(text = element_text(size=16))
```

Usando Cores Efetivamente em Gráficos

Princípios de Escolha de Cores


Escolhas claras de cores ajudam a transmitir significado e manter uma identidade visual consistente em suas visualizações.

Use ColorBrewer para selecionar paletas:

- **Sequential:** para dados ordenados que progridem de baixo para alto
- **Diverging:** para desvios de um ponto médio, destacando variações
- **Qualitative:** para dados categóricos sem ordem específica


```
#install.packages("RColorBrewer")
library(RColorBrewer)
colors <- brewer.pal(4, 'Set1')
```

Links: colorbrewer2.org | rdrr.io/cran/RColorBrewer




Sequential

Escala contínua do claro ao escuro



Qualitative

Cores distintas para categorias



Diverging

Duas cores divergindo de um ponto médio




Gráfico de Dispersão (Scatter Plot)

Quando Usar


Gráficos de dispersão são usados para mostrar a relação entre duas variáveis numéricas, o que pode ajudar a identificar tendências, agrupamentos ou valores atípicos nos dados.

Código de Exemplo

```
library(dplyr)
data <- iris |>
  select(x = Sepal.Length,
         value = Sepal.Width,
         variable = Species)

grf <- plot_scatter(data,
                    label_x = "Sepal.Length",
                    label_y = "Sepal.Width",
                    colors=colors[1:3]) + font
plot(grf)
```

Documentação: [grf_scatter.md](#)



Este gráfico mostra a relação entre comprimento e largura das sépalas para três espécies diferentes de íris, revelando padrões distintos de agrupamento.

Gráfico de Barras (Bar Graph)

Características

Gráficos de barras são ideais para comparar quantidades entre categorias. Eles são simples, eficazes e amplamente utilizados em análise categórica.

Aplicações Comuns


- Comparação de médias entre grupos
- Visualização de contagens por categoria
- Apresentação de resultados agregados

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(Sepal.Length=mean(Sepal.Length))

grf <- plot_bar(data, colors=colors[1:3]) + font
plot(grf)
```

Documentação: [grf_bar.md](#)



Este gráfico compara o comprimento médio das sépalas entre as três espécies de íris, facilitando a identificação de diferenças significativas.

Gráfico Lollipop

Vantagens Visuais

Um gráfico lollipop apresenta as mesmas informações que um gráfico de barras, mas com um estilo visual mais limpo e leve — especialmente eficaz quando há muitas categorias a serem exibidas.

Quando Preferir Lollipops


- Muitas categorias para visualizar
- Necessidade de um visual mais moderno
- Redução de "tinta" no gráfico
- Foco nos valores específicos

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(Sepal.Length=mean(Sepal.Length))

grf <- plot_lollipop(data,
  colors=colors[1],
  max_value_gap=0.2) +
  font + coord_flip()
plot(grf)
```

Documentação: [grf_lollipop.md](#)



A orientação horizontal (`coord_flip`) facilita a leitura de rótulos de categoria longos e cria um visual elegante.

Gráfico de Barras com Barras de Erro

Representando Variabilidade

Usado para mostrar médias com variabilidade associada, como intervalos de confiança ou desvios padrão. As barras de erro comunicam a incerteza ou dispersão dos dados.

Interpretação


Barras de erro maiores indicam maior variabilidade nos dados, enquanto barras menores sugerem dados mais consistentes. Este tipo de visualização é essencial em pesquisas científicas.

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(mean=mean(Sepal.Length),
            sd=sd(Sepal.Length))

grf <- plot_bar(data, colors=colors[1], alpha=1) + font
grf <- grf +
  geom_errorbar(aes(x=Species,
                    ymin=mean-sd,
                    ymax=mean+sd),
                width=0.2, colour="darkred",
                alpha=0.8, size=1.1)
plot(grf)
```

Documentação: [grf_bar_error.md](#)



As barras vermelhas mostram um desvio padrão acima e abaixo da média, fornecendo contexto sobre a variabilidade dos dados.

Gráfico de Pizza (Pie Chart)

Representação de Proporções

Gráfico estatístico circular usado para ilustrar proporções numéricas. Cada fatia representa uma categoria, e o tamanho da fatia é proporcional à quantidade que ela representa.

Considerações de Uso


Embora populares, gráficos de pizza devem ser usados com cautela. Eles funcionam melhor com poucas categorias (3-5) e quando as diferenças entre as proporções são substanciais.

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(n = n())

grf <- plot_pieplot(data, colors=colors[1:3]) + font
plot(grf)
```

Documentação: [grf_pie.md](#)



Neste exemplo, as três espécies de íris estão igualmente representadas no dataset, cada uma com 33.3% do total.

Gráfico de Barras Agrupadas

Comparações Multidimensionais

Gráficos de barras agrupadas permitem comparar subcategorias dentro de categorias principais. Cada grupo mostra barras lado a lado, uma por subcategoria.

Aplicações


- Comparar múltiplas métricas por categoria
- Análise temporal com várias séries
- Estudos comparativos entre grupos

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(Sepal.Length=mean(Sepal.Length),
            Sepal.Width=mean(Sepal.Width))

grf <- plot_groupedbar(data, colors=colors[1:2]) + font
plot(grf)
```

Documentação: [grf_grouped_bar.md](#)



Este gráfico compara simultaneamente o comprimento e a largura médios das sépalas para cada espécie, facilitando análises comparativas multidimensionais.

Gráfico de Barras Empilhadas

Visualizando Totais Compostos

A altura da barra mostra o resultado combinado dos grupos. Este tipo de gráfico é útil para mostrar como diferentes componentes contribuem para um total.

Vantagens


- Mostra tanto os totais quanto as partes
- Facilita comparação de composição
- Economiza espaço horizontal

Código de Exemplo

```
library(dplyr)
data <- iris |>
  group_by(Species) |>
  summarize(Sepal.Length=mean(Sepal.Length),
            Sepal.Width=mean(Sepal.Width))

grf <- plot_stackedbar(data, colors=colors[1:2]) + font
grf <- grf +
  theme(axis.text.x = element_text(angle=90, hjust=1))
plot(grf)
```

Documentação: [grf_stacked_bar.md](#)



Observe como os rótulos do eixo x foram rotacionados em 90 graus para melhorar a legibilidade quando os nomes das categorias são longos.

Gráfico de Linhas (Line Chart)

Visualizando Tendências Temporais

Gráficos de linhas são usados para exibir tendências ao longo do tempo ou qualquer sequência contínua. Eles são particularmente eficazes em análise de séries temporais, onde a ordem dos pontos de dados é importante.

Características

Cada ponto é conectado com linhas para destacar a evolução dos valores. Isso torna fácil identificar tendências, ciclos, picos e vales nos dados.


Aplicações Comuns

- Análise de séries temporais
- Monitoramento de KPIs ao longo do tempo
- Visualização de funções matemáticas
- Comparação de múltiplas tendências

Código de Exemplo

```
x <- seq(0, 10, 0.25)
serie <- data.frame(x, y=sin(x))

grf <- plot_series(serie, colors=colors[1]) + font
plot(grf)
```



Este exemplo mostra a função seno, demonstrando como gráficos de linhas podem visualizar efetivamente padrões cíclicos e comportamentos contínuos.



Visualização de Distribuições de Dados

Um guia completo para escolher e criar visualizações eficazes que revelam padrões, outliers e características fundamentais das suas distribuições de dados. Aprenda a comunicar insights estatísticos com clareza e precisão.

Preparando os Dados de Exemplo

Para demonstrar diferentes técnicas de visualização de distribuição, começamos criando um conjunto de dados sintético com três tipos distintos de distribuições estatísticas:

- **Exponencial:** 10.000 valores gerados com taxa = 1, representando eventos aleatórios ao longo do tempo
- **Uniforme:** 10.000 valores distribuídos igualmente entre 2,5 e 3,5
- **Normal:** 10.000 valores com média = 5, seguindo a curva em sino clássica

Essa abordagem permite comparar como diferentes visualizações revelam as características únicas de cada distribuição.

```
example <- data.frame(  
  exponential = rexp(10000, rate = 1),  
  uniform = runif(10000, min=2.5, max = 3.5),  
  normal = rnorm(10000, mean = 5)  
)  
  
head(example)
```

❏ Usar variáveis aleatórias permite explorar visualmente como cada tipo de distribuição se manifesta em diferentes formatos gráficos.

Histogramas: Contando e Comparando Frequências

O que é um histograma?

Um histograma organiza uma única variável contínua em **bins** (intervalos) e conta quantas observações caem em cada intervalo. É ideal para:

- Identificar a forma geral da distribuição
- Detectar assimetrias e outliers
- Visualizar concentração de valores
- Avaliar normalidade dos dados

```
library(dplyr)
data <- example |>
  select(exponential)


grf <- plot_hist(data,
  label_x = "exponential",
  color=colors[1]) + font

plot(grf)
```

Comparando Múltiplas Distribuições

Visualizar múltiplos histogramas lado a lado revela diferenças fundamentais entre distribuições.

```
library(gridExtra)
grfe <- plot_hist(example |> select(exponential), label_x = "exponential", color=colors[1]) + font
grfu <- plot_hist(example |> select(uniform), label_x = "uniform", color=colors[1]) + font
grfn <- plot_hist(example |> select(normal), label_x = "normal", color=colors[1]) + font
grid.arrange(grfe, grfu, grfn, ncol=3)
```



Distribuição exponencial mostrando alta frequência próxima a zero com cauda longa à direita

Exponencial


Concentração extrema em valores baixos com cauda longa.

Uniforme

Distribuição plana onde todos os valores têm probabilidade igual.

Normal

Curva em sino simétrica, a distribuição mais comum na natureza.



Gráficos de Densidade: Suavizando a Distribuição

Estimativa Kernel de Densidade


Enquanto histogramas usam bins discretos, gráficos de densidade criam uma **curva suave e contínua** que estima a função de densidade de probabilidade subjacente.

Vantagens sobre histogramas:

- Visualização mais suave e esteticamente clara
- Não depende da escolha arbitrária de bins
- Facilita comparação de múltiplas distribuições
- Revela multimodalidade com mais clareza

```
library(dplyr)
data <- example |>
  select(normal)

grf <- plot_density(data,
  label_x = "normal",
  color=colors[1]) + font
plot(grf)
```



- ❏ A curva de densidade integra para 1, representando 100% da probabilidade total. A altura em qualquer ponto indica densidade relativa, não probabilidade absoluta.

Box Plots: Resumo Estatístico Visual

Anatomia do Box Plot

Box plots (diagramas de caixa) agrupam dados numéricos através de seus **quartis**, fornecendo um resumo visual poderoso de cinco estatísticas-chave:

Mínimo

Menor valor (excluindo outliers)

Q1 (25%)

Primeiro quartil

Mediana (50%)


Valor central

Q3 (75%)

Terceiro quartil

Máximo

Maior valor (excluindo outliers)



```
library(dplyr)
data <- example |>
  select(normal)

grf <- plot_boxplot(data,
  color="white") + font

plot(grf)
```

A caixa contém 50% dos dados centrais (IQR), com pontos individuais representando outliers potenciais.

 [Documentação completa](#)

Escolhendo a Visualização Certa

Selecionar o tipo de gráfico apropriado é fundamental para comunicar sua mensagem com eficácia. Esta tabela conecta objetivos analíticos com as visualizações mais adequadas.

Objetivo da Análise	Gráfico Recomendado
Comparar valores entre categorias	Gráfico de barras, barras agrupadas/empilhadas
Mostrar parte de um todo	Gráfico de pizza, barras empilhadas
Mostrar distribuição	Histograma, boxplot, gráfico de densidade
Mostrar relacionamentos	Gráfico de dispersão, lollipop
Mostrar tendências temporais	Gráfico de linha (séries temporais)
Comparar grupos com variabilidade	Gráfico de barras com barras de erro

Melhores Práticas em Visualização

Visualização de dados eficaz é sobre **comunicação, não decoração**. Seguir estes princípios garante que seus gráficos sejam claros, precisos e impactantes.

Rótulos Claros

Use títulos descritivos em eixos e legendas. Seu público não deveria adivinhar o que está visualizando.

Cores Acessíveis

Use paletas de cores como ColorBrewer que são distinguíveis para pessoas com daltonismo.

Guie a Interpretação

Use tooltips ou anotações para destacar insights importantes e facilitar a compreensão.

"O objetivo da visualização é comunicação - não decoração."

— Edward Tufte, pioneiro em visualização de dados

Tipo Adequado

Combine o tipo de gráfico com sua estrutura de dados e pergunta de pesquisa. Não force dados em formatos inadequados.

Evite Chartjunk

Remova decoração desnecessária como efeitos 3D, sombras excessivas ou elementos que não agregam informação.

Escalas Consistentes

Mantenha unidades e escalas consistentes ao comparar múltiplos gráficos ou visualizações.


Referências



Hands-on Programming with R

Aprenda a escrever suas próprias funções e simulações

rstudio-education.github.io/hopr



R Graphics Cookbook

Guia para criar visualizações


r-graphics.org



R Packages

Desenvolva e compartilhe seus próprios pacotes R

r-pkgs.org



R for Data Science

Referência para análise de dados

r4ds.had.co.nz

Leitura adicional sobre fundamentos: <https://rstudio-education.github.io/hopr/basics.html>