




Regressão - Fundamentos

Uma introdução clara aos fundamentos da análise de regressão, explorando os conceitos essenciais, tipos de modelos e aplicações práticas na ciência de dados.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

O Que É Regressão?

A análise de regressão é um nome coletivo para técnicas de modelagem que permitem construir um modelo a partir de dados para modelar a relação entre variáveis independentes (preditoras) e uma variável dependente (resposta), produzindo previsões numéricas precisas para valores contínuos ou ordenados.

Semelhanças com Classificação

A regressão numérica compartilha alguns princípios com a classificação: ambas envolvem construir um modelo a partir de dados e usá-lo para fazer previsões. No entanto, enquanto a classificação prevê categorias discretas (como "aprovado" ou "reprovado"), a regressão prevê valores contínuos ou ordenados.

Diferenças Importantes

A principal distinção está na natureza da variável de resposta. Classificação lida com rótulos categóricos, enquanto regressão modela funções de valores contínuos. Isso permite que a regressão capture relações quantitativas entre variáveis e produza previsões numéricas precisas.

Processo de Regressão

Coleta de Dados

Reunir observações das variáveis preditoras e da variável resposta.

Estimação

Ajustar os parâmetros do modelo minimizando o erro entre previsões e valores reais.

Ajuste do Modelo

Avaliar a qualidade do modelo e refinar para melhorar o desempenho preditivo.

Aplicações Principais

- Previsão de valores contínuos, como preços, temperaturas e demanda
- Modelagem de relações quantitativas entre variáveis em experimentos científicos
- Análise de tendências temporais e séries históricas
- Suporte à tomada de decisão com base em estimativas numéricas

Variáveis em um Modelo de Regressão

Variável Dependente (Y)

Também chamada de variável de resposta ou variável explicada. É o resultado que queremos prever ou entender. Representa o valor que muda em resposta às variáveis independentes.

Variável Independente (X)

Conhecida como variável explicativa, preditora ou feature. São os fatores que utilizamos para explicar ou prever a variável dependente. Podem ser uma ou múltiplas variáveis.

Coeficientes

Parâmetros do modelo que quantificam a relação entre variáveis independentes e dependente. São estimados a partir dos dados e determinam a força e direção das relações.

Quando Usar Regressão?

A regressão é a ferramenta ideal quando seu objetivo é prever valores numéricos contínuos e existe uma relação quantitativa identificável entre as variáveis do problema.

Preço de Imóveis

Estimar valor de propriedades com base em características como localização, área, número de quartos e idade da construção.

Demanda por Produtos

Prever volume de vendas considerando fatores como preço, sazonalidade, campanhas publicitárias e condições econômicas.

Tempo de Execução

Calcular duração de processos computacionais baseado em tamanho de dados, complexidade do algoritmo e recursos de hardware.

Risco ou Custo Esperado

Avaliar probabilidade de perdas financeiras ou estimar custos operacionais usando variáveis de risco identificadas.

Principais Tipos de Regressão

Regressão Linear Simples

Modelo mais básico que relaciona uma única variável explicativa (X) com a variável resposta (Y). Ideal para entender relações diretas e lineares entre duas variáveis. Fácil de interpretar e implementar.

Regressão Polinomial

Adequada para relações não lineares entre variáveis, usando potências das variáveis independentes. Captura curvaturas e padrões mais complexos nos dados. Útil quando a relação não é uma linha reta.

Regressão Linear Múltipla

Extensão que incorpora várias variáveis explicativas simultaneamente. Permite capturar efeitos combinados de múltiplos fatores na variável resposta. Mais realista para problemas complexos do mundo real.

Regressão Não Linear

Categoria ampla para modelos com formas funcionais não lineares nos parâmetros. Necessária para fenômenos com comportamento exponencial, logarítmico ou outras formas complexas. Requer técnicas de estimação mais sofisticadas.

Intuição do Método dos Mínimos Quadrados

O método dos mínimos quadrados é a técnica mais comum para encontrar a melhor reta que se ajusta aos dados. Sua elegância está na simplicidade matemática e nas propriedades estatísticas desejáveis.

Algoritmo: Mínimos Quadrados Ordinários (OLS)
Regressão Linear Simples: $y = \beta_0 + \beta_1 x + \varepsilon$

ENTRADA: X (vetor de n observações), y (vetor de n respostas)

PRÉ-CONDIÇÃO: $n > 2$, dados numéricos

PASSO 1 — Calcular Médias

$$\bar{x} \leftarrow \text{média}(X)$$

$$\bar{y} \leftarrow \text{média}(y)$$

PASSO 2 — Calcular Coeficiente Angular (β_1)

$$\text{numerador} \leftarrow \sum (x_i - \bar{x})(y_i - \bar{y}) \quad \# \text{ covariância}$$

$$\text{denominador} \leftarrow \sum (x_i - \bar{x})^2 \quad \# \text{ variância de } X$$

$$\beta_1 \leftarrow \text{numerador} / \text{denominador}$$

PASSO 3 — Calcular Intercepto (β_0)

$$\beta_0 \leftarrow \bar{y} - \beta_1 \cdot \bar{x}$$

PASSO 4 — Gerar Predições e Resíduos

PARA CADA i de 1 até n :

$$\hat{y}_i \leftarrow \beta_0 + \beta_1 \cdot x_i \quad \# \text{ valor predito}$$

$$e_i \leftarrow y_i - \hat{y}_i \quad \# \text{ resíduo}$$

SAÍDA: β_0 , β_1 , vetor de resíduos e

PÓS-CONDIÇÃO: $\sum e_i^2$ é minimizado (solução ótima)

Verossimilhança e MLE

Enquanto o Método dos Mínimos Quadrados (OLS) minimiza os erros quadráticos entre os valores observados e previstos, a Estimação por Máxima Verossimilhança (MLE) encontra os parâmetros do modelo que maximizam a probabilidade de observar os dados reais. Sob a suposição de normalidade dos erros, ambos os métodos convergem para a mesma solução para os coeficientes de regressão.

A grande vantagem do MLE é sua generalidade. Ele funciona mesmo quando os erros não são normalmente distribuídos, tornando-se a base para uma classe mais ampla de modelos de regressão, como os Modelos Lineares Generalizados (GLMs), que podem lidar com variáveis de resposta que seguem distribuições como Poisson ou Binomial.

Algoritmo: Maximum Likelihood Estimation (MLE)
Regressão Linear: assume erros $\varepsilon \sim N(0, \sigma^2)$

ENTRADA: X (matriz $n \times p$), y (vetor de respostas)

PRÉ-CONDIÇÃO: erros i.i.d., distribuição especificada

PASSO 1 — Definir Log-Verossimilhança

$$\ell(\beta, \sigma^2) \leftarrow -n/2 \cdot \log(2\pi\sigma^2) - (1/2\sigma^2) \cdot \sum (y_i - x_i^T\beta)^2$$

PASSO 2 — Maximizar em relação a β

$$\partial\ell/\partial\beta = 0 \rightarrow \hat{\beta} \leftarrow (X^TX)^{-1} X^Ty \quad \# \text{ idêntico ao OLS!}$$

PASSO 3 — Estimar Variância Residual

$$\hat{\sigma}^2 \leftarrow (1/n) \cdot \sum (y_i - x_i^T\hat{\beta})^2 \quad \# \text{ MLE (ligeiramente enviesado)}$$
$$s^2 \leftarrow (1/(n-p)) \cdot \sum e_i^2 \quad \# \text{ OLS (não-enviesado)}$$

PASSO 4 — Calcular Log-Verossimilhança Maximizada

$$\ell_{\text{max}} \leftarrow -n/2 \cdot (1 + \log(2\pi \cdot \hat{\sigma}^2)) \quad \# \text{ usada em AIC/BIC}$$

SAÍDA: $\hat{\beta}$, $\hat{\sigma}^2$, ℓ_{max}

PÓS-CONDIÇÃO: sob normalidade, $\hat{\beta}_{\text{MLE}} = \hat{\beta}_{\text{OLS}}$

Boston Housing Dataset

O conjunto de dados Boston Housing é amplamente utilizado para ilustrar técnicas de regressão. Contém informações sobre valores de imóveis em diferentes bairros de Boston e diversas características socioeconômicas e estruturais que podem influenciar esses preços.

crim	zn	indus	chas	nox	rm	age	dis	rad	tax	ptratio	black	lstat	medv
0.00632	18	2.31	0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	4.98	24.0
0.02731	0	7.07	0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	9.14	21.6
0.02729	0	7.07	0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
0.03237	0	2.18	0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
0.06905	0	2.18	0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	5.33	36.2
0.02985	0	2.18	0	0.458	6.430	58.7	6.0622	3	222	18.7	394.12	5.21	28.7

📄 **Variáveis Principais:** O dataset inclui medidas como taxa de criminalidade, proporção de residências antigas, distância a centros de emprego, índices de qualidade das escolas, e a variável resposta: valor médio das casas.

Ajustando o Primeiro Modelo

Construção do Modelo

Neste exemplo, modelamos o preço das casas usando a variável LSTAT (percentual de população com status socioeconômico baixo). A função `lm()` no R constrói o modelo de regressão linear, enquanto `summary()` fornece estatísticas detalhadas sobre a qualidade e significância do ajuste.

```
lm.fit = lm(medv ~ lstat, data = Boston)
summary(lm.fit)
```

Call:

```
lm(formula = medv ~ lstat, data = Boston)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.168	-3.990	-1.318	2.034	24.500

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.55384	0.56263	61.41	<2e-16 ***
lstat	-0.95005	0.03873	-24.53	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.216 on 504 degrees of freedom

Multiple R-squared: 0.5441, Adjusted R-squared: 0.5432

F-statistic: 601.6 on 1 and 504 DF, p-value: < 2.2e-16

O output mostra informações cruciais: os coeficientes estimados, seus erros padrão, valores-t e p-valores para testes de significância. O R^2 indica quanto da variação no preço é explicada pelo modelo, enquanto o erro padrão residual mede a qualidade geral do ajuste.

Ajuste da Regressão Linear Simples

O processo de ajuste busca encontrar os parâmetros ótimos que minimizam o erro de predição. Este procedimento matemático resulta em estimativas que possuem propriedades estatísticas desejáveis, como não-viés e variância mínima.

Algoritmo: Ajuste e Avaliação — Regressão Linear Simples

Critério: Minimização da Soma dos Quadrados dos Resíduos (SQR)

ENTRADA: β_0 , β_1 (estimados por OLS), X , y

PRÉ-CONDIÇÃO: coeficientes já estimados

PASSO 1 — Gerar Predições

PARA CADA i de 1 até n :

$$\hat{y}_i \leftarrow \beta_0 + \beta_1 \cdot x_i$$

PASSO 2 — Calcular Resíduos e SQR

PARA CADA i de 1 até n :

$$e_i \leftarrow y_i - \hat{y}_i$$

$$\text{SQR} \leftarrow \sum e_i^2 \quad \# \text{ soma dos quadrados dos resíduos}$$

PASSO 3 — Calcular R^2 (Coeficiente de Determinação)

$$\text{SQT} \leftarrow \sum (y_i - \bar{y})^2 \quad \# \text{ variação total}$$

$$R^2 \leftarrow 1 - (\text{SQR} / \text{SQT}) \quad \# \text{ proporção explicada}$$

PASSO 4 — Calcular Erro Padrão Residual

$$s \leftarrow \sqrt{(\text{SQR} / (n - 2))} \quad \# \text{ graus de liberdade} = n - 2$$

SAÍDA: $\hat{y}$, R^2 , s (erro padrão residual)

PÓS-CONDIÇÃO: $R^2 \in [0,1]$; s mede dispersão média dos resíduos

Interpretação dos Coeficientes

Intercepto (β_0)

Representa o valor esperado da variável resposta Y quando todas as variáveis explicativas X são iguais a zero. Nem sempre possui interpretação prática significativa, especialmente quando $X = 0$ está fora do intervalo observado.

Coeficiente Angular (β_1)

Sinal: Indica a direção da relação. Positivo significa que Y aumenta quando X aumenta; negativo indica relação inversa.

Magnitude: Quantifica a intensidade do efeito. Representa a mudança esperada em Y para cada unidade de aumento em X.

📌 **⚠️ Alerta Importante:** Os coeficientes expressam relação estatística, não necessariamente causal. Correlação não implica causalção. Conclusões causais requerem design experimental apropriado ou técnicas avançadas de inferência causal.

Predição e Visualização do Modelo

Utilizando o modelo ajustado para fazer previsões e visualizando os resultados para avaliar qualidade e identificar padrões. A função `predict()` utiliza o modelo ajustado para gerar previsões de novos valores, acompanhadas de intervalos que quantificam a incerteza associada às estimativas.

Tipos de Intervalos

Existem dois tipos principais de intervalos em regressão, cada um respondendo a uma pergunta diferente sobre a incerteza nas previsões. É fundamental entender qual tipo usar dependendo do objetivo da análise.

Análise Detalhada

Para compreensão aprofundada sobre as diferenças entre intervalos de confiança, previsão e tolerância, consulte recursos especializados como Statistics By Jim que explicam as nuances e aplicações de cada tipo.

Intervalos em Regressão

Intervalo de Confiança

Quantifica a incerteza sobre a **média estimada** da população.
Responde à pergunta: "Quão precisa é nossa estimativa do valor médio de Y para um dado valor de X?"

É mais estreito porque estima um parâmetro populacional (a média), que tem menos variabilidade que observações individuais.

Intervalo de Predição

Quantifica a incerteza sobre uma **nova observação individual**.
Responde: "Onde esperamos que um novo valor individual de Y caia para um dado X?"


É sempre mais largo que o intervalo de confiança porque incorpora tanto a incerteza da média estimada quanto a variabilidade individual das observações.

Comportamento dos Intervalos: Ambos os tipos de intervalos se alargam à medida que nos afastamos da região central dos dados observados. Isso reflete o aumento da incerteza ao fazer previsões fora da faixa de valores onde temos informação empírica.

Visualizando e Diagnosticando o Modelo

Importância da Visualização

É uma boa prática sempre visualizar o modelo de regressão ajustado. A visualização nos permite ter uma intuição imediata sobre a qualidade do ajuste, identificar padrões nos dados e detectar potenciais problemas que estatísticas resumidas podem não revelar.



Detectar Padrões Não Lineares

Identificar se a relação entre variáveis segue uma curva não capturada pelo modelo linear simples.

Avaliar Heterocedasticidade

Verificar se a variância dos erros é constante ao longo dos valores preditos, um pressuposto fundamental da regressão.

A análise visual complementa as métricas numéricas: enquanto o R^2 e os p-valores resumem o ajuste globalmente, os gráficos diagnósticos revelam estruturas locais e violações de pressupostos que podem comprometer a validade das inferências.

Identificar Outliers

Observações com resíduos muito grandes que podem influenciar desproporcionalmente o ajuste do modelo.

Validar Pressupostos

Confirmar visualmente que os pressupostos do modelo são razoáveis antes de interpretar os resultados.

Limitações da Regressão Linear Simples

Relações Não Lineares

Muitos fenômenos do mundo real não seguem padrões perfeitamente lineares. A temperatura não aumenta linearmente com a altitude, e o crescimento de vendas não é constante ao longo do tempo. Modelos lineares simples podem falhar ao capturar essas curvaturas naturais.

Subajuste dos Dados

Quando o modelo é excessivamente simples para a complexidade dos dados, ele subajusta, falhando em capturar padrões importantes. Isso resulta em baixo poder preditivo e perda de insights valiosos sobre as relações subjacentes.

Preditor Único Insuficiente

Raramente um fenômeno complexo depende de apenas uma variável. O preço de imóveis, por exemplo, depende de área, localização, idade e outras características. Ignorar essas dimensões múltiplas resulta em modelos incompletos e imprecisos.

Necessidade de Flexibilidade

Modelos rígidos limitam nossa capacidade de expressar conhecimento sobre o domínio. Extensões da regressão linear oferecem flexibilidade controlada, permitindo maior complexidade sem abandonar a interpretabilidade e simplicidade matemática dos modelos lineares.

Polynomial Regression

Adicionando Dimensões Polinomiais

A regressão polinomial introduz potências da variável independente no modelo. Por exemplo, ao invés de apenas x , incluimos x^2 , x^3 , e assim por diante. Isso permite que o modelo capture curvaturas e padrões não lineares nos dados.

Insight fundamental: Apesar de modelar relações não lineares entre y e x , o modelo continua sendo linear nos parâmetros. Isso significa que ainda podemos usar mínimos quadrados ordinários e todas as propriedades matemáticas dos modelos lineares.

A flexibilidade aumenta com o grau do polinômio, mas devemos equilibrar complexidade com interpretabilidade e risco de overfitting.

```
lm.fit_p = lm(medv ~ lstat + I(lstat^2), data = Boston)
summary(lm.fit_p)
```

Call:

```
lm(formula = medv ~ lstat + I(lstat^2), data = Boston)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.2834	-3.8313	-0.5295	2.3095	25.4148

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	42.862007	0.872084	49.15	<2e-16 ***
lstat	-2.332821	0.123803	-18.84	<2e-16 ***
I(lstat^2)	0.043547	0.003745	11.63	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.524 on 503 degrees of freedom
Multiple R-squared: 0.6407, Adjusted R-squared: 0.6393
F-statistic: 448.5 on 2 and 503 DF, p-value: < 2.2e-16

Regressão Polinomial: Intuição Geométrica

Introduz Potências da Variável

Cada termo polinomial adicional (x^2 , x^3 , etc.) permite que o modelo capture uma nova "ondulação" ou curvatura nos dados, aumentando progressivamente a flexibilidade do ajuste.

Linear nos Parâmetros

Matematicamente, o modelo permanece linear em seus coeficientes (β_0 , β_1 , β_2 ...), permitindo estimação por mínimos quadrados ordinários e mantendo propriedades estatísticas conhecidas.

Permite Curvas Flexíveis

Com graus polinomiais mais altos, podemos modelar desde curvaturas suaves até padrões complexos com múltiplos picos e vales, adaptando-se melhor à forma real dos dados.

Aumenta Risco de Overfitting

Polinômios de grau muito alto podem ajustar perfeitamente os dados de treino, mas capturando ruído aleatório ao invés de padrões reais, resultando em previsões ruins para novos dados.


Visualizando a Regressão Polinomial

Plotagem na Dimensão Original

Ao visualizar regressão polinomial, é suficiente plotar no espaço bidimensional original (x vs y). Não precisamos representar explicitamente as dimensões polinomiais (x^2 , x^3), pois elas são transformações da variável base.

A curva resultante mostra naturalmente como o modelo captura não linearidades, permitindo avaliar visualmente a qualidade do ajuste e identificar possíveis problemas como overfitting ou underfitting.

❏ **Dica prática:** Compare visualmente diferentes graus polinomiais para entender o trade-off entre flexibilidade e simplicidade.



Comparação Formal de Modelos

Modelos Mais Complexos

Sempre ajustam melhor os dados de treino, reduzindo o erro residual. Isso é matematicamente garantido, mas não significa melhor desempenho real.

Critérios Formais

Precisamos de métricas estatísticas objetivas para decidir entre modelos concorrentes, evitando julgamentos subjetivos ou enviesados.

Comparar modelos é uma etapa crítica na modelagem. Não basta escolher o modelo com menor erro – devemos avaliar se a melhoria é estatisticamente significativa e se o modelo mais complexo oferece ganhos práticos que justifiquem sua maior dificuldade de interpretação e possível perda de generalização.

Pergunta Central

O ganho em ajuste compensa a complexidade adicional? Devemos balancear precisão com simplicidade e generalização.

ANOVA como Ferramenta

A Análise de Variância oferece um teste estatístico rigoroso para comparar modelos aninhados formalmente.

Avaliando Regressão Polinomial com ANOVA

Teste de Hipóteses

Hipótese Nula (H_0): Os modelos não são estatisticamente diferentes. O aumento de complexidade não oferece ganho significativo. Evidência: p-valor $> 5\%$.

Hipótese Alternativa (H_1): Os modelos são significativamente diferentes. O modelo mais complexo captura padrões reais nos dados. Evidência: p-valor $< 5\%$.

A ANOVA decompõe a variação total e testa se a redução no erro residual é maior do que esperaríamos por acaso.

Interpretação Prática

- p-valor baixo (< 0.05): Rejeitamos H_0 , o modelo complexo é justificado
- p-valor alto (> 0.05): Mantemos H_0 , a complexidade adicional não se justifica
- Considere também o contexto do domínio, não apenas significância estatística
- Avalie múltiplas métricas: R^2 , AIC, BIC para decisão robusta

Overfitting: O Perigo da Complexidade Excessiva

Aprende Ruído, Não Padrão

O modelo memoriza variações aleatórias específicas dos dados de treino, confundindo ruído estatístico com sinal real. Isso cria uma ilusão de precisão que não se traduz em capacidade preditiva.

Comum em Modelos Complexos

Quanto maior o grau do polinômio ou o número de parâmetros, maior o risco de overfitting. Modelos muito flexíveis têm capacidade de se adaptar a qualquer padrão, incluindo aqueles que não deveriam ser modelados.

Ajuste Excelente, Predição Ruim

Nos dados de treino, o modelo parece perfeito, com erro residual próximo de zero. Porém, ao encontrar novos dados, o desempenho colapsa dramaticamente, revelando que o modelo não aprendeu relações generalizáveis.

Deve Ser Evitado

Em aplicações reais, queremos modelos que generalizem bem. Técnicas como validação cruzada, regularização e seleção cuidadosa de features ajudam a prevenir overfitting e garantir modelos robustos.

Interpretação em Regressão Múltipla

Efeito Marginal

Cada coeficiente β representa o impacto de aumentar uma unidade na variável correspondente, mantendo todas as outras constantes. Por exemplo, $\beta_1 = 5000$ significa que cada metro quadrado adicional aumenta o preço em R\$ 5.000, assumindo localização, idade e outras variáveis fixas.

Ceteris Paribus

A interpretação assume que "tudo o mais permanece igual" (cláusula *ceteris paribus*). Na prática, variáveis raramente mudam isoladamente, mas essa abstração matemática permite quantificar efeitos individuais de forma clara e sistemática.

Interpretação Cautelosa

Coeficientes isolados podem ser enganosos. Devemos considerar significância estatística (valores-p), intervalos de confiança, e plausibilidade prática. Um coeficiente estatisticamente significativo pode não ser praticamente relevante, e vice-versa.

Multiple Regression

Expandindo o Modelo

A regressão múltipla generaliza o modelo linear simples para incluir múltiplas variáveis independentes simultaneamente. Matematicamente:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_n x_n + \varepsilon$$

Cada variável x_i contribui independentemente para predizer y , e o modelo estima o peso ideal (β_i) de cada contribuição através de mínimos quadrados ordinários.

Isso permite capturar fenômenos complexos que dependem de múltiplos fatores, como preço de imóveis (área, localização, idade) ou desempenho de vendas (preço, marketing, sazonalidade).

```
lm.fit2 = lm(medv ~ lstat + age, data = Boston)
summary(lm.fit2)
```

Call:

```
lm(formula = medv ~ lstat + age, data = Boston)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.981	-3.978	-1.283	1.968	23.158

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	33.22276	0.73085	45.458	< 2e-16 ***
lstat	-1.03207	0.04819	-21.416	< 2e-16 ***
age	0.03454	0.01223	2.826	0.00491 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.173 on 503 degrees of freedom

Multiple R-squared: 0.5513, Adjusted R-squared: 0.5495

F-statistic: 309 on 2 and 503 DF, p-value: < 2.2e-16

📌 **Importante:** Geometricamente, deixamos de ajustar uma linha em 2D ou curva em 2D e passamos a ajustar um hiperplano em múltiplas dimensões.

Verificando Significância do Modelo

ANOVA para Regressão Múltipla

A ANOVA testa a hipótese nula de que **todos** os coeficientes (exceto o intercepto) são zero simultaneamente. Ou seja, verifica se o modelo como um todo tem poder preditivo.

Um p-valor baixo (< 0.05) indica que pelo menos uma das variáveis é significativa, justificando o uso do modelo de regressão múltipla ao invés de simplesmente prever a média de y .

```
anova(lm.fit, lm.fit2)
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	504	19472.38	NA	NA	NA	NA
2	503	19168.13	1	304.2528	7.984043	0.004906776

F-statistic Alto

Indica que a variação explicada pelo modelo é muito maior que a variação residual não explicada.

P-valor Baixo

Evidência forte contra H_0 , confirmando que o modelo tem capacidade preditiva real.

R² Ajustado

Complementa ANOVA, penalizando complexidade excessiva e ajudando na seleção de variáveis.

Multicolinearidade: Intuição e Impactos

O que é?

Ocorre quando duas ou mais variáveis explicativas são altamente correlacionadas entre si. Por exemplo, área construída e número de quartos em imóveis, ou temperatura e consumo de energia.

Dificulta Interpretação

Não conseguimos atribuir com confiança o efeito observado a uma variável específica, pois seu impacto está confundido com o de outras variáveis correlacionadas.

Coefficientes Instáveis

Quando variáveis são correlacionadas, o algoritmo de mínimos quadrados tem dificuldade em separar seus efeitos individuais, resultando em estimativas que variam dramaticamente com pequenas mudanças nos dados.

Predição vs Inferência

Multicolinearidade é problemática para inferência (entender relações causais), mas menos crítica para predição pura. Se o objetivo é apenas prever y , o modelo pode funcionar bem apesar da multicolinearidade.

Diagnóstico: Use o Variance Inflation Factor (VIF) para quantificar multicolinearidade. $VIF > 10$ indica problema sério.

Visualizando Superfícies de Regressão Múltipla


Explorando Múltiplas Perspectivas

Com duas variáveis independentes, podemos visualizar a regressão como uma superfície tridimensional, onde o plano ajustado flutua sobre os pontos de dados.

Rotar e explorar diferentes ângulos ajuda a:

- Identificar padrões de ajuste e resíduos
- Visualizar como as variáveis interagem
- Detectar outliers multidimensionais
- Avaliar a planaridade do ajuste

Além de três dimensões, a visualização torna-se desafiadora, exigindo técnicas como projeções, cores ou animações.



Desafios da Alta Dimensionalidade

Visualização Impossível

Com mais de três variáveis, perdemos a capacidade de visualizar diretamente os dados e o modelo ajustado. Isso dificulta a detecção visual de problemas e a compreensão intuitiva das relações.

Seleção de Variáveis

Nem todas as variáveis disponíveis são úteis. Incluir variáveis irrelevantes aumenta variância dos coeficientes sem melhorar previsões. Técnicas como stepwise selection, Lasso ou análise de importância são essenciais.

A "maldição da dimensionalidade" não invalida modelos lineares, mas exige abordagens mais cuidadosas e ferramentas estatísticas robustas para garantir modelos confiáveis e generalizáveis.

Risco Maior de Overfitting

Quanto mais variáveis, maior a capacidade do modelo de memorizar ruído. Em alta dimensão, modelos podem ajustar perfeitamente dados de treino mesmo sem relações reais, exigindo validação rigorosa.

Motivação para Métodos Avançados

Esses desafios motivam técnicas mais sofisticadas: regularização (Ridge, Lasso), redução de dimensionalidade (PCA), métodos ensemble, e aprendizado profundo para capturar complexidade sem sacrificar generalização.

Métodos de ML para Regressão

Os algoritmos de Machine Learning, muitos dos quais já foram apresentados para classificação, podem ser adaptados para tarefas de regressão. O foco aqui é entender as diferenças e adaptações, passando de uma saída discreta (classes) para uma saída contínua .

Método	Saída	Função de Perda / Critério	Interpretabilidade	Custo Computacional
KNN Regressor	Média dos k vizinhos	Distância (Euclidiana, Manhattan)	Alta (vizinhos)	Alto (predição)
Árvore de Decisão	Média dos nós folha	Redução da variância (MSE/MAE)	Média a Alta (regras claras)	Baixo
Random Forest	Média das árvores	Redução da variância (MSE/MAE)	Baixa (ensemble)	Médio a Alto
Gradient Boosting	Soma sequencial de árvores	Gradiente sobre função de perda (MSE, MAE)	Baixa (ensemble complexo)	Alto (treinamento)
SVR	Função de decisão	Minimiza erro dentro de margem ϵ	Baixa (kernels)	Médio a Alto
Redes Neurais	Valor contínuo	MSE, MAE	Muito Baixa ("caixa preta")	Muito Alto

Adaptações para Regressão: KNN, Árvores e Ensembles

Embora muitos algoritmos de Machine Learning sejam versáteis, sua aplicação em problemas de regressão exige adaptações específicas em seus critérios e formas de agregação, focando na predição de valores contínuos em vez de classes discretas.

KNN Regressor

Em vez de voto majoritário para determinar a classe, o KNN Regressor calcula a **média** (ou média ponderada pela distância) dos k vizinhos mais próximos. É sensível à escala das variáveis, tornando a normalização essencial.

Random Forest Regressor

Este ensemble **agrega previsões por média** das árvores individuais (não por votação como na classificação). A importância das variáveis é calculada pela redução média do Erro Quadrático Médio (MSE). É robusto a outliers e geralmente não requer normalização.

Árvore de Decisão para Regressão

O critério de divisão muda drasticamente: em vez de Gini/Entropia, a árvore minimiza a **variância (MSE)** dentro dos nós. Cada nó folha retorna a média dos valores de treino presentes naquele nó.

Gradient Boosting (XGBoost/LightGBM)

Ajusta árvores sequencialmente sobre os **resíduos do modelo anterior**, buscando corrigir os erros. A função de perda é diferenciável (ex: MSE, MAE, Huber), permitindo um ajuste preciso. É extremamente poderoso para dados tabulares.

Adaptações para Regressão: SVR e Redes Neurais

SVR (Support Vector Regression)

- Em vez de maximizar a margem entre classes como no SVM, o SVR busca uma função que se ajuste aos dados dentro de uma margem de tolerância ϵ (epsilon-tube).
- Pontos de dados que caem dentro do "epsilon-tube" não contribuem para o erro, tornando o modelo robusto a ruídos.
- Somente os pontos fora do tubo (vetores de suporte) definem a função de regressão.
- Utiliza funções kernel (RBF, polinomial) para capturar relações não lineares complexas.
- Hiperparâmetros cruciais: C (penalidade para erros fora do tubo), ϵ (largura do tubo de tolerância) e o tipo de kernel.

Redes Neurais para Regressão

- A principal adaptação é na camada de saída, que utiliza uma única unidade linear (sem função de ativação) para produzir um valor contínuo.
- A função de perda é alterada para métricas de regressão como Erro Quadrático Médio (MSE) ou Erro Absoluto Médio (MAE), em vez de cross-entropy.
- Graças ao teorema da aproximação universal, redes neurais podem modelar qualquer função contínua.
- Requerem grandes volumes de dados e um ajuste cuidadoso de hiperparâmetros (taxa de aprendizado, arquitetura, regularização).
- Oferecem a vantagem de escalar eficientemente com grandes conjuntos de dados, superando o SVR nesse aspecto.

Métricas de Avaliação em Regressão

A avaliação de modelos de regressão é crucial para entender seu desempenho e capacidade de generalização. Ao contrário da classificação, que lida com categorias discretas, a regressão prevê valores contínuos, exigindo métricas específicas para medir o erro de previsão.

MAE (Mean Absolute Error)

Média dos erros absolutos. Fácil de interpretar, na mesma unidade de Y. Por ser menos sensível a outliers, é preferível quando erros extremos não devem ter um peso desproporcional.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

RMSE (Root Mean Squared Error)

A raiz quadrada do MSE. Retorna à unidade original de Y, combinando a sensibilidade a outliers do MSE com a interpretabilidade do MAE. Facilita a comparação com a magnitude da variável de resposta.

MSE (Mean Squared Error)

Média dos erros ao quadrado. Penaliza erros grandes mais severamente devido à quadratura. É muito usado como função de perda no treinamento de modelos, incentivando o modelo a evitar grandes desvios.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

R² (Coeficiente de Determinação)

Proporção da variância da variável dependente (Y) que é explicada pelo modelo. Varia de 0 a 1 (onde 1 indica um ajuste perfeito). Um R² ajustado penaliza a inclusão de variáveis irrelevantes em modelos múltiplos.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$



Não existe uma métrica universal — a escolha depende do problema. MAE é preferível quando outliers não devem ter peso extra; RMSE quando erros grandes são especialmente custosos.

Regularização: Ridge, Lasso e Elastic Net

A regularização é uma técnica crucial em modelos de regressão para evitar o overfitting e melhorar a capacidade de generalização, especialmente em conjuntos de dados com muitas variáveis correlacionadas ou de alta dimensionalidade. Ela adiciona um termo de penalidade à função de perda do modelo.

O Conceito por Trás da Regularização

- **O Problema:** Em regressão múltipla, o OLS pode superajustar (overfit) os dados e gerar coeficientes instáveis quando há muitas variáveis, especialmente com multicolinearidade.
- **A Solução:** Adicionar um termo de penalidade λ à função de perda para "encolher" os coeficientes em direção a zero, reduzindo a complexidade do modelo.
- **Controle:** O hiperparâmetro λ (lambda) controla a intensidade da regularização. $\lambda = 0$ equivale ao OLS, enquanto $\lambda \rightarrow \infty$ força todos os coeficientes a zero.

Ridge (Penalidade L2)

Adiciona $\lambda \sum \beta_j^2$ à função de perda. Encolhe os coeficientes, mas raramente os zera. Ideal quando todas as variáveis têm alguma contribuição. Muito estável em cenários de multicolinearidade.

Lasso (Penalidade L1)

Adiciona $\lambda \sum |\beta_j|$ à função de perda. Tem a capacidade de zerar coeficientes, realizando uma seleção automática de variáveis. Perfeito para modelos esparsos e de alta dimensionalidade.

Elastic Net

Combina as penalidades L1 e L2. Permite balancear a seleção de variáveis do Lasso com a estabilidade do Ridge. Extremamente útil quando há grupos de variáveis altamente correlacionadas.

Validação Cruzada em Regressão

A validação cruzada é uma técnica essencial para a seleção robusta de modelos e hiperparâmetros, garantindo que o desempenho estimado seja representativo da capacidade de generalização em dados não vistos, sem sobreajustar os dados de teste.

Conceito e Motivação

- O desafio é escolher o grau ideal de um polinômio ou o λ de regularização sem "espiar" os dados de teste.
- A Validação Cruzada (CV) estima o erro de generalização dividindo os dados de treino em **k subconjuntos (folds)**.
- Em cada iteração, **k-1 folds** são usados para treinar o modelo e **1 fold** é usado para validar.
- O erro de generalização estimado é a **média dos erros** obtidos em cada fold de validação.
- Valores comuns para **k são 5 ou 10**. O Leave-One-Out (LOO-CV) utiliza $k = n$ (o número total de amostras).
- Métricas de validação típicas em regressão incluem **RMSE ou MAE médio** entre os folds.

1. Definir Grade de Hiperparâmetros

Especifique os valores a serem testados, como graus do polinômio (ex: 1 a 10) ou λ para Ridge/Lasso (ex: {0.001, 0.01, 0.1, 1, 10}).

2. Executar k-fold CV e Calcular RMSE

Para cada hiperparâmetro da grade, realize a validação cruzada e calcule o RMSE (ou MAE) médio nas previsões dos folds de validação.

3. Selecionar e Retreinar

Escolha o hiperparâmetro com o menor RMSE de validação e retreine o modelo final usando **todos os dados de treino** com esse hiperparâmetro.

❏ Validação cruzada é a resposta prática ao overfitting: permite comparar modelos de complexidades diferentes de forma honesta, sem contaminar os dados de teste.

Referências Principais

Esta seleção de referências representa os pilares fundamentais para o estudo aprofundado de mineração de dados, cobrindo desde conceitos básicos até técnicas avançadas e aplicações contemporâneas.



1. **J. Han, J. Pei, and H. Tong**, *Data Mining: Concepts and Techniques*, 4th edition. Cambridge, MA: Morgan Kaufmann, 2022.
2. **G. M. James, D. Witten, T. Hastie, and R. Tibshirani**, *An Introduction to Statistical Learning: With Applications in R*. Springer Nature, 2021.
3. **S. Garcia, J. Luengo, and F. Herrera**, *Data Preprocessing in Data Mining*. Springer, 2014.
4. **C. M. Bishop and H. Bishop**, *Deep Learning: Foundations and Concepts*. Springer Nature, 2023.