

Clustering Explicado: K-means, DBSCAN e validação de grupos

O Que É Análise de Cluster?

Conceitos Fundamentais

Um **cluster** é uma coleção de objetos de dados que compartilham características semelhantes dentro do mesmo grupo, mas são dissimilares aos objetos em outros grupos. A análise de cluster é o processo de identificar similaridades entre dados com base nas características encontradas e agrupá-los em clusters significativos.

Aprendizado Não Supervisionado

Diferente de métodos supervisionados, não existem classes predefinidas. O algoritmo aprende por observação, descobrindo padrões naturais nos dados sem exemplos rotulados.

Aplicações Típicas

- Ferramenta independente para compreender a distribuição de dados
- Etapa de pré-processamento para outros algoritmos de análise
- Descoberta de estruturas ocultas em grandes conjuntos de dados

Aplicações da Análise de Cluster

A análise de cluster oferece soluções versáteis para diversos desafios em ciência de dados, desde redução dimensional até detecção de anomalias. Suas aplicações práticas transformam dados brutos em insights acionáveis.

Redução de Dados

Sumarização e compressão de conjuntos de dados para pré-processamento em regressão, PCA, classificação e análise de associação, tornando análises subsequentes mais eficientes.

K-Vizinhos Mais Próximos

Localização eficiente de busca limitando-a a um ou poucos clusters, otimizando significativamente o tempo de processamento em grandes datasets.

Predição Baseada em Grupos

Identificação de características e padrões distintos para cada grupo, permitindo previsões mais precisas e segmentação estratégica de dados.

Detecção de Outliers

Identificação de valores atípicos como pontos distantes de qualquer cluster, essencial para garantir qualidade e integridade dos dados.

Exemplos Práticos de Clustering

Marketing

Descoberta de grupos distintos nas bases de clientes, permitindo que profissionais de marketing desenvolvam programas direcionados e personalizados para cada segmento identificado.

Planejamento Urbano

Identificação de grupos de residências de acordo com tipo, valor e localização geográfica, auxiliando no desenvolvimento de políticas públicas e infraestrutura adequada.

Climatologia

Compreensão do clima terrestre através da identificação de padrões atmosféricos e oceânicos, fundamentais para previsões meteorológicas e estudos de mudanças climáticas.

📌 **Insight:** Estas aplicações demonstram a versatilidade do clustering em transformar dados complexos em conhecimento acionável em diversos domínios.

Características de Um Clustering de Qualidade

"Um método de clustering eficaz produz clusters de alta qualidade com forte coesão interna e clara distinção entre grupos."

Princípios Fundamentais

- **Alta similaridade intra-classe:** Objetos dentro do mesmo cluster devem ser altamente coesos e semelhantes entre si
- **Baixa similaridade inter-classe:** Clusters diferentes devem ser distintivos e bem separados
- **Padrões ocultos:** Capacidade de descobrir estruturas não óbvias nos dados

Medida de Similaridade

A escolha da métrica apropriada impacta diretamente a qualidade dos resultados

Implementação

A eficiência e robustez do algoritmo utilizado

Descoberta de Padrões

Capacidade de revelar estruturas significativas e acionáveis

Considerações Para Análise de Cluster

A escolha adequada de parâmetros e abordagens é crucial para o sucesso da análise de cluster. Diversos fatores devem ser cuidadosamente avaliados antes da implementação.

Critérios de Particionamento

Nível único vs. hierárquico: Particionamento hierárquico multi-nível é frequentemente desejável, oferecendo diferentes níveis de granularidade na análise.

Medida de Similaridade

Baseada em distância vs. conectividade: Distância euclidiana, rede viária, vetorial versus densidade ou contiguidade espacial.

Separação de Clusters

Exclusivo vs. não-exclusivo: Clusters exclusivos (um cliente pertence a apenas uma região) ou não-exclusivos (um documento pode pertencer a múltiplas classes).

Espaço de Clustering

Espaço completo vs. subespaços: Espaço completo em baixa dimensionalidade versus subespaços em clustering de alta dimensão.

Requisitos e Desafios

Escalabilidade

Capacidade de realizar clustering em todos os dados, não apenas em amostras, mantendo eficiência computacional mesmo com datasets massivos.

Tipos de Atributos

Habilidade para lidar com atributos numéricos, binários, categóricos, ordinais, vinculados e misturas destes diferentes tipos de dados.

Clustering Baseado em Restrições

Usuários podem fornecer inputs sobre restrições, utilizando conhecimento de domínio para determinar parâmetros de entrada.

Interpretabilidade e Usabilidade

Os resultados devem ser compreensíveis e aplicáveis, traduzindo descobertas técnicas em insights acionáveis.

Formas Arbitrárias

Descoberta de clusters com formas complexas e não-convexas

Dados Ruidosos

Robustez para lidar com ruído e outliers

Clustering Incremental

Insensibilidade à ordem de entrada dos dados

Alta Dimensionalidade

Eficácia em espaços de alta dimensão

Etapas Básicas Para Desenvolver Uma Tarefa de Clustering

O desenvolvimento sistemático de uma solução de clustering requer seguir etapas bem definidas, desde a seleção inicial de características até a validação e interpretação final dos resultados.

Seleção de Características

Selecionar informações relevantes à tarefa de interesse, minimizando redundância e maximizando o poder discriminativo dos dados.

Medida de Similaridade

Definir como calcular a similaridade entre dois vetores de características, escolhendo métricas apropriadas ao tipo de dados.

Critério de Clustering

Expressar objetivos através de uma função de custo ou conjunto de regras que guiem o processo de agrupamento.

Algoritmos de Clustering

Escolher algoritmos apropriados considerando escalabilidade, tipos de dados e requisitos específicos da aplicação.

Validação dos Resultados

Aplicar testes de validação e tendência de clustering para avaliar objetivamente a qualidade dos agrupamentos obtidos.

Interpretação dos Resultados

Integrar descobertas com aplicações práticas, traduzindo resultados técnicos em insights de negócio acionáveis.

Similaridade e Dissimilaridade

Similaridade

Medida numérica de quão semelhantes são dois objetos de dados. O valor é mais alto quando os objetos são mais parecidos, frequentemente variando no intervalo $[0,1]$. Esta métrica quantifica a proximidade conceitual entre elementos.

Dissimilaridade (Distância)

Medida numérica de quão diferentes são dois objetos de dados. Valores mais baixos indicam maior semelhança. A dissimilaridade mínima é frequentemente 0, enquanto o limite superior varia conforme a métrica utilizada.

 **Proximidade:** Termo genérico que se refere tanto à similaridade quanto à dissimilaridade entre objetos de dados.

Distância de Minkowski para Dados Numéricos

A distância de Minkowski é uma família generalizada de métricas de distância amplamente utilizada para dados numéricos. Esta fórmula fornece uma estrutura flexível que engloba várias medidas de distância comuns através da variação do parâmetro h .

Fórmula Geral

A distância de Minkowski entre dois objetos i e j é definida como:

$$d(i, j) = \sqrt[h]{\sum_{f=1}^p |x_{if} - x_{jf}|^h}$$

onde p é o número de dimensões e h é o parâmetro de ordem.

Propriedades

- Métrica positiva e simétrica
- Satisfaz a desigualdade triangular
- Parametrizável através de h
- Aplicável a espaços multidimensionais

Variações da Distância de Minkowski

Diferentes valores do parâmetro h na fórmula de Minkowski produzem métricas de distância com propriedades e aplicações distintas. Cada variação possui características únicas que a tornam adequada para diferentes cenários analíticos.

Distância de Manhattan ($h=1$)

$$d(i, j) = \sum_{f=1}^p |x_{if} - x_{jf}|$$

Também conhecida como distância L1 ou City Block. Mede a distância percorrida ao longo de eixos em ângulos retos, como em uma grade urbana.

Distância Euclidiana ($h=2$)

$$d(i, j) = \sqrt{\sum_{f=1}^p (x_{if} - x_{jf})^2}$$

A métrica de distância mais comum, representando a linha reta entre dois pontos no espaço euclidiano.

Distância de Chebyshev ($h \rightarrow \infty$)

$$d(i, j) = \max_{f=1}^p |x_{if} - x_{jf}|$$

Também chamada de distância L^∞ ou distância do máximo. Define distância como a maior diferença em qualquer dimensão.

Medidas de Proximidade para Atributos Binários

Atributos binários requerem abordagens especializadas para cálculo de similaridade. A tabela de contingência organiza as concordâncias e discordâncias entre dois objetos, permitindo o cálculo de diversos coeficientes de similaridade.

Tabela de Contingência

Objeto i = 1	q	r	q+r
Objeto i = 0	s	t	s+t
Soma	q+s	r+t	p

Coeficientes

Coeficiente de Correspondência Simples (SMC):

$$SMC = \frac{q + t}{q + r + s + t}$$

Coeficiente de Jaccard:

$$J = \frac{q}{q + r + s}$$

📌 **Nota:** O coeficiente de Jaccard é equivalente à medida de "coerência" e ignora concordâncias negativas (t).

Dissimilaridade entre Variáveis Binárias

Para ilustrar o cálculo de dissimilaridade, consideremos atributos com diferentes características de simetria. O gênero representa um atributo simétrico, enquanto os demais atributos são binários assimétricos. Atribuímos valor 1 para Y e P, e valor 0 para N.

Identificar Tipo de Atributo

Classifique cada atributo como simétrico ou assimétrico. Atributos simétricos tratam ambos os estados igualmente, enquanto assimétricos dão maior peso a uma condição.

Construir Tabela de Contingência

Organize os dados em uma matriz 2x2, contabilizando concordâncias positivas (q), discordâncias (r, s) e concordâncias negativas (t).

Aplicar Fórmula Apropriada

Para atributos assimétricos, use Jaccard. Para simétricos, use SMC. Calcule a dissimilaridade como 1 menos a similaridade obtida.

Medidas de Proximidade para Atributos Nominais

Atributos nominais representam categorias sem ordem intrínseca, como cores, marcas ou tipos. Para estes dados, utilizamos abordagens baseadas em correspondência de categorias, contando o número de atributos que coincidem entre objetos.

Método de Correspondência Simples

A dissimilaridade entre dois objetos i e j pode ser calculada como:

$$d(i, j) = \frac{p - m}{p}$$

onde p é o número total de atributos e m é o número de correspondências (atributos com valores iguais).

Alternativamente, a similaridade pode ser expressa como:

$$sim(i, j) = \frac{m}{p}$$

Ponderação de Atributos

Podemos atribuir pesos diferentes a cada atributo conforme sua importância, resultando em uma medida ponderada:

$$d(i, j) = \frac{\sum_{f=1}^p w_f \delta_f(i, j)}{\sum_{f=1}^p w_f}$$

Tratamento de Variáveis Ordinais

Variáveis ordinais possuem uma ordem natural entre suas categorias, como classificações (baixo, médio, alto) ou rankings. Para calcular distâncias, transformamos estas categorias em valores numéricos preservando a ordenação, depois normalizamos para o intervalo [0,1].

Mapeamento de Ranks

Atribua ranks sequenciais às categorias ordinais: 1, 2, 3, ..., M_f , onde M_f é o número de categorias do atributo f .

Normalização

Transforme cada rank para o intervalo [0,1] usando a fórmula:

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

onde r_{if} é o rank do objeto i no atributo f , e z_{if} é o valor normalizado resultante.

Cálculo de Distância

Aplique qualquer métrica de distância (como Euclidiana ou Manhattan) aos valores normalizados z_{if} , tratando-os como dados numéricos contínuos.

Similaridade do Cosseno

A similaridade do cosseno mede o cosseno do ângulo entre dois vetores em um espaço multidimensional. Esta métrica é especialmente útil em mineração de texto e recuperação de informação, pois é invariante à magnitude dos vetores, focando apenas em sua direção.

Interpretação Geométrica

Dois vetores com orientação similar terão um cosseno próximo de 1, independentemente de suas magnitudes. Vetores perpendiculares resultam em cosseno 0, enquanto vetores opostos produzem -1.

Fórmula da Similaridade

$$\cos(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \cdot \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \cdot \sqrt{\sum_{i=1}^n B_i^2}}$$

O numerador calcula o produto interno dos vetores **A** e **B**, enquanto o denominador normaliza pelo produto de suas magnitudes, garantindo que o resultado permaneça em [-1, 1].

Aplicação em Documentos

Frequentemente usada para comparar documentos representados como vetores de termos, onde cada dimensão corresponde a uma palavra e o valor à sua frequência.

Sistemas de Recomendação

Útil para encontrar itens similares baseando-se em perfis de usuários ou características de produtos em espaços de alta dimensionalidade.


Divergência KL: Comparando Distribuições

A divergência KL mede a informação perdida quando $\mathbf{q}(\mathbf{x})$ é usada para aproximar $\mathbf{p}(\mathbf{x})$. É uma medida assimétrica: $\mathbf{DKL}(\mathbf{p}||\mathbf{q}) \neq \mathbf{DKL}(\mathbf{q}||\mathbf{p})$.

Forma Discreta

$$D_{KL}(p(x)||q(x)) = \sum_{x \in X} p(x) \ln \left(\frac{p(x)}{q(x)} \right)$$

A assimetria implica que a ordem das distribuições importa: aproximar p por q tem custo diferente do que aproximar q por p.



Em Clustering

- Comparar distribuições de clusters em modelos probabilísticos
- Base para critérios de seleção de modelos como BIC e AIC

Combinando Tipos Mistos de Dados

Conjuntos de dados reais frequentemente contêm atributos de tipos diversos: numéricos, nominais, ordinais e binários. Para calcular distâncias entre objetos com atributos heterogêneos, precisamos de uma abordagem unificada que respeite as características de cada tipo de dado.

Normalização por Tipo

Cada tipo de atributo requer tratamento específico: atributos numéricos são normalizados para $[0,1]$, ordinais são convertidos em ranks normalizados, e nominais usam correspondência binária (0 ou 1).

Ponderação Adaptativa

Atributos podem receber pesos diferentes baseados em sua relevância ou confiabilidade. Atributos com valores ausentes podem ter peso zero para aquele par de objetos específico.

Fórmula Generalizada

A dissimilaridade combinada usa uma soma ponderada das contribuições de cada atributo:

$$d(i, j) = \frac{\sum_{f=1}^p w_f \cdot \delta_f(i, j)}{\sum_{f=1}^p w_f}$$

❏ **Importante:** A função $\delta_f(i, j)$ é escolhida apropriadamente para cada tipo de atributo, e o peso w_f pode ser ajustado para refletir a importância ou disponibilidade do atributo.

Principais Abordagens de Clustering (I)

As técnicas de clustering dividem-se em várias categorias baseadas em seus princípios fundamentais e estratégias algorítmicas. Cada abordagem oferece vantagens distintas para diferentes cenários de análise de dados.

Abordagem por Particionamento

Constrói várias partições do conjunto de dados e as avalia segundo critérios como minimização da soma dos erros quadrados. Métodos eficientes para grandes conjuntos de dados.

- **K-means:** Algoritmo clássico baseado em centroides
- **K-medoids:** Mais robusto a outliers que k-means
- **CLARANS:** Eficiente para dados espaciais

Abordagem Hierárquica

Cria uma decomposição hierárquica do conjunto de dados usando algum critério, resultando em uma estrutura de árvore (dendrograma) que pode ser cortada em diferentes níveis.

- **DIANA:** Abordagem divisiva (top-down)
- **AGNES:** Abordagem aglomerativa (bottom-up)
- **BIRCH, CAMELEON:** Métodos escaláveis

Abordagem Baseada em Densidade

Baseia-se em funções de conectividade e densidade para identificar clusters de formas arbitrárias. Especialmente útil para detectar outliers e clusters não-esféricos.

- **DBSCAN:** Density-Based Spatial Clustering
- **OPTICS:** Ordering Points To Identify Clustering
- **DENCLUE:** Baseado em estimativa de densidade

O Método K-Means

Um dos algoritmos de clustering mais populares, eficiente e de fácil implementação. Dado k clusters, encontra partições que minimizam a variação intra-cluster.

- **Objetivo:** minimizar a soma das distâncias ao centroide
- **Critério de parada:** estabilidade nas atribuições
- **Complexidade:** $O(tkn)$, onde t = iterações

Algoritmo K-Means

Referência: MacQueen (1967)

ENTRADA: D (conjunto de n objetos), k (n° de clusters)

PRÉ-CONDIÇÃO: $k \leq n$, dados numéricos

PASSO 1 — Inicialização

Selecionar k objetos aleatórios como centroides iniciais $\mu_1, \dots, \mu_k$

PASSO 2 — Atribuição (E-step)

PARA CADA objeto x_i em D :

$c_i \leftarrow \operatorname{argmin}_j \text{dist}(x_i, \mu_j)$

cluster mais próximo

PASSO 3 — Atualização (M-step)

PARA CADA cluster j de 1 até k :

$\mu_j \leftarrow \text{média}(\{x_i : c_i = j\})$

novo centroide

PASSO 4 — Convergência

SE atribuições não mudaram: PARAR

SENÃO: voltar ao PASSO 2

SAÍDA: k clusters $C_1, \dots, C_k$ e centroides $\mu_1, \dots, \mu_k$

PÓS-CONDIÇÃO: minimiza $\sum_i \text{dist}(x_i, \mu_{c_i})^2$

Comentários sobre o Método K-Means

✓ Vantagens

- Implementação simples e intuitiva
- Escalável para grandes conjuntos de dados
- Converge rapidamente na maioria dos casos práticos
- Funciona bem com clusters aproximadamente esféricos e de tamanhos similares

⚠ Limitações e Problemas

- **Média sem significado:** o centroide pode cair em região vazia, não representando nenhum objeto real — problemático em dados categóricos ou muito dispersos
- **Mínimo local:** altamente dependente da inicialização; diferentes centroides iniciais levam a soluções distintas, todas mínimos locais válidos
- **k predefinido:** o número de clusters deve ser especificado antecipadamente, o que nem sempre é conhecido
- **Sensível a outliers** e ruído nos dados
- **Apenas dados numéricos;** dificuldade com clusters de formas não convexas ou tamanhos muito diferentes

O Método K-Medoids

Alternativa robusta ao K-Means que utiliza **medoides** — objetos reais do conjunto de dados — em vez de centroides calculados.

- Robusto a outliers
- Usa objetos reais como representantes
- Complexidade $O(k(n-k)^2)$

Algoritmo K-Medoids (PAM)

Referência: Kaufman & Rousseeuw (1987)

ENTRADA: D (conjunto de n objetos), k (nº de clusters)

PRÉ-CONDIÇÃO: $k \leq n$

PASSO 1 — Inicialização

Selecionar k objetos aleatórios como medoides iniciais $M = \{m_1, \dots, m_k\}$

PASSO 2 — Atribuição

PARA CADA objeto x_i em D:

$c_i \leftarrow \operatorname{argmin}_j \operatorname{dist}(x_i, m_j)$

medoide mais próximo

PASSO 3 — Avaliação de Troca

PARA CADA medoide m_j e não-medoide x_h :

Calcular custo de trocar m_j por x_h :

$TC(j,h) \leftarrow \sum_i [\operatorname{dist}(x_i, \text{melhor_medoide_sem_}m_j\text{_com_}x_h) - \operatorname{dist}(x_i, m_j)]$

PASSO 4 — Atualização

SE $\min TC(j,h) < 0$:

Realizar troca: $M \leftarrow M \setminus \{m_j\} \cup \{x_h\}$

Voltar ao PASSO 2

SENÃO: PARAR

SAÍDA: k clusters e medoides $m_1, \dots, m_k$

PÓS-CONDIÇÃO: minimiza $\sum_i \operatorname{dist}(x_i, m_{c_i})$

Centroide, Raio e Diâmetro de um Cluster

Para conjuntos de dados numéricos, três medidas fundamentais caracterizam a geometria e dispersão dos clusters:

Centroide

O centroide C_m é o ponto médio de um cluster, calculado como a média de todos os pontos no cluster. É representado matematicamente como a média vetorial de todos os objetos pertencentes ao cluster m .

$$C_m = \frac{1}{|C_m|} \sum_{x \in C_m} x$$

Raio

O raio R_m representa a dispersão média do cluster, calculado como a raiz quadrada da distância média ao quadrado de todos os objetos no cluster ao seu centroide. Menor raio indica cluster mais compacto.

$$R_m = \sqrt{\frac{1}{|C_m|} \sum_{x \in C_m} d(x, C_m)^2}$$

Diâmetro

O diâmetro D_m é a raiz quadrada da distância média ao quadrado entre todos os pares de objetos no cluster. Mede a máxima extensão do cluster e sua coesão interna.

$$D_m = \sqrt{\frac{1}{|C_m|(|C_m| - 1)} \sum_{x, y \in C_m} d(x, y)^2}$$

Distância entre Clusters

A escolha da medida de distância entre clusters é fundamental para o sucesso do clustering hierárquico. Diferentes métricas capturam diferentes aspectos da similaridade entre grupos.

Single Linkage (Vizinho Mais Próximo)

Distância mínima entre quaisquer dois pontos nos diferentes clusters. Tende a criar clusters alongados (efeito "corrente").

$$d_{min}(C_i, C_j) = \min_{p \in C_i, q \in C_j} d(p, q)$$

Complete Linkage (Vizinho Mais Distante)

Distância máxima entre quaisquer dois pontos nos diferentes clusters. Produz clusters mais compactos e balanceados.

$$d_{max}(C_i, C_j) = \max_{p \in C_i, q \in C_j} d(p, q)$$

Average Linkage (Ligação Média)

Distância média entre todos os pares de pontos nos diferentes clusters. Oferece compromisso entre single e complete.

$$d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{p \in C_i} \sum_{q \in C_j} d(p, q)$$

Centroid Linkage (Ligação por Centroide)

Distância entre os centroides dos clusters. Intuitiva mas pode sofrer com inversões no dendrograma.

$$d_{centroid}(C_i, C_j) = d(c_i, c_j)$$

Clustering Hierárquico

O clustering hierárquico utiliza uma matriz de distâncias como critério de agrupamento, construindo uma hierarquia de clusters através de fusões ou divisões sucessivas.

Características Principais

- **Não requer k predefinido:** Diferentemente do K-Means, não necessita especificar o número de clusters antecipadamente
- **Estrutura hierárquica:** Produz uma árvore de clusters (dendrograma) que captura relações em múltiplos níveis
- **Critério de terminação:** Necessita de uma condição de parada, como altura do corte no dendrograma ou número desejado de clusters
- **Flexibilidade:** Permite explorar diferentes níveis de granularidade no agrupamento

Abordagens

Aglomerativa (bottom-up): Inicia com cada objeto como um cluster e sucessivamente funde os clusters mais próximos.

Divisiva (top-down): Inicia com todos os objetos em um único cluster e sucessivamente divide em clusters menores.

Clustering Hierárquico Aglomerativo

Abordagem bottom-up que funde os dois clusters mais próximos a cada iteração, produzindo um dendrograma completo.

- Não requer k predefinido
- Resultado: dendrograma cortável em qualquer nível
- Complexidade: $O(n^2 \log n)$ com heap
- Linkage: single, complete, average ou centroid

Algoritmo AGNES (Agglomerative Nesting)

Referência: Kaufman & Rousseeuw (1990)

ENTRADA: D (conjunto de n objetos), linkage (critério de fusão)

PRÉ-CONDIÇÃO: $n \geq 2$, matriz de distâncias $M[i,j]$ definida

PASSO 1 — Inicialização

PARA CADA objeto x_i em D :

$C_i \leftarrow \{x_i\}$ # cada objeto é seu próprio cluster

$C \leftarrow \{C_1, C_2, \dots, C_n\}$ # conjunto de n clusters

Calcular $M[i,j] = \text{dist}(C_i, C_j)$ para todo $i \neq j$

PASSO 2 — Fusão Iterativa

ENQUANTO $|C| > 1$:

$(i^*, j^*) \leftarrow \text{argmin}_{\{i \neq j\}} M[i,j]$ # par de clusters mais próximos

$C_{\text{novo}} \leftarrow C_{i^*} \cup C_{j^*}$ # fundir os dois clusters

Registrar fusão no dendrograma com altura $M[i^*, j^*]$

Remover C_{i^*} e C_{j^*} de C

Adicionar C_{novo} a C

PARA CADA cluster C_k restante:

$M[\text{novo}, k] \leftarrow \text{linkage}(C_{\text{novo}}, C_k)$ # atualizar distâncias

PASSO 3 — Corte (opcional)


Dado k desejado ou limiar de altura h :

Cortar dendrograma $\rightarrow$ obter k clusters finais

SAÍDA: Dendrograma completo + k clusters após corte

PÓS-CONDIÇÃO: hierarquia aninhada de todos os n objetos

Dendrograma: Visualizando a Fusão de Clusters



O dendrograma é uma representação visual em forma de árvore que mostra como os clusters são fundidos (ou divididos) em cada etapa do algoritmo hierárquico.

Níveis Aninhados

Decompõe os objetos de dados em vários níveis de particionamento aninhado, criando uma árvore de clusters com múltiplas camadas

Corte no Dendrograma

Um clustering dos objetos é obtido cortando o dendrograma no nível desejado. A altura do corte determina o número e granularidade dos clusters

Componentes Conectados

Cada componente conectado após o corte forma um cluster independente, permitindo visualizar as relações de similaridade

Métodos de Clustering Baseados em Densidade

Visão Geral

Clusters = regiões de **alta densidade** separadas por regiões de **baixa densidade**.

- **Forma Arbitrária:** descobre clusters de qualquer geometria, não apenas esféricos
- **Tratamento de Ruído:** isola outliers que não pertencem a nenhum cluster denso
- **Eficiência:** requer apenas uma varredura dos dados
- **Parâmetros de Densidade:** define condições de terminação para regiões "densas"

Algoritmos Principais

DBSCAN

OPTICS

DENCLUE

CLIQUE

Conceitos Fundamentais

Eps (ϵ) – Raio de Vizinhança

Raio máximo que define a vizinhança de um ponto

MinPts – Mínimo de Pontos

Número mínimo de pontos exigido para caracterizar uma região densa

Ponto Core

Possui $\geq$ **MinPts** pontos dentro do raio Eps; núcleo de um cluster

Ponto Border

Está dentro do Eps de um ponto core, mas não possui MinPts próprios

Ponto Outlier / Ruído

Não é core nem border; excluído de qualquer cluster

DBSCAN: Density-Based Spatial Clustering of Applications with Noise

O DBSCAN é um dos algoritmos de clustering baseado em densidade mais populares e influentes, introduzindo uma abordagem revolucionária para descoberta de clusters.

Noção de Cluster Baseada em Densidade

Um cluster é definido como um **conjunto maximal de pontos conectados por densidade**. Pontos que não pertencem a nenhum cluster são classificados como ruído.

Descoberta de Formas Arbitrárias

Ao contrário do K-Means, o DBSCAN não assume nenhuma forma predefinida para os clusters, permitindo identificar estruturas complexas como anéis, serpentinas ou qualquer geometria irregular.

Density-Reachable e Density-Connected

Alcançável: p é alcançável a partir de q se existe uma cadeia de pontos core ligando-os (relação *assimétrica*). **Conectado:** p e q são conectados se ambos são alcançáveis a partir de um ponto comum (relação *simétrica*). Esta conectividade define os clusters.

"DBSCAN revolucionou o clustering ao demonstrar que a densidade local é um critério mais robusto do que a distância a centroides para muitas aplicações do mundo real."

O Algoritmo DBSCAN

O DBSCAN opera examinando cada ponto e expandindo clusters a partir de pontos core identificados por densidade local.

- Detecta clusters de formas arbitrárias
- Trata ruído automaticamente
- Complexidade $O(n \log n)$ com índice espacial
- Requer apenas uma varredura do banco de dados

Algoritmo DBSCAN

Referência: Ester et al. (1996)

ENTRADA: D (conjunto de n pontos), Eps (raio), MinPts (mínimo de vizinhos)

PRÉ-CONDIÇÃO: Eps > 0, MinPts ≥ 1

PASSO 1 — Inicialização

Marcar todos os pontos como NÃO_VISITADO

cluster_id ← 0

PASSO 2 — Iteração Principal

PARA CADA ponto p não visitado em D:

Marcar p como VISITADO

N ← vizinhos(p, Eps) # Eps-vizinhança de p

p é ponto CORE se |N| ≥ MinPts

SE |N| < MinPts:

Classificar p como RUÍDO # pode ser reclassificado

SENÃO:

cluster_id ← cluster_id + 1

ExpandirCluster(p, N, cluster_id, Eps, MinPts)

FUNÇÃO ExpandirCluster(p, N, id, Eps, MinPts):

Adicionar p ao cluster id

PARA CADA ponto q em N:

SE q não visitado:

Marcar q como VISITADO

N' ← vizinhos(q, Eps)

SE |N'| ≥ MinPts: N ← N ∪ N'

q é density-reachable a partir de p

SE q não pertence a nenhum cluster:

Adicionar q ao cluster id

todos os pontos no cluster id são # density-connected:

SAÍDA: Clusters $C_1, \dots, C_k$ e pontos de ruído


PÓS-CONDIÇÃO: todo ponto é core, border ou ruído

Determinando o Número Ideal de Clusters

Uma das decisões mais críticas em clustering é determinar quantos grupos são apropriados para seus dados. Esta escolha fundamental impacta diretamente a qualidade e interpretabilidade dos resultados.

Métodos populares incluem a análise do cotovelo (elbow method), índice de silhueta, e critérios estatísticos como BIC e AIC. Cada abordagem oferece perspectivas diferentes sobre a estrutura ótima de agrupamento.

A escolha do número de clusters deve equilibrar complexidade do modelo com capacidade de generalização, considerando também o contexto e objetivos do domínio de aplicação.



Medindo a Qualidade do Clustering

A avaliação de qualidade em clustering utiliza três paradigmas distintos, cada um com propósitos e aplicações específicas. Compreender estas abordagens é essencial para validar resultados de agrupamento.

Medidas Externas

Abordagem supervisionada que compara clustering contra conhecimento prévio ou ground truth.

- Entropia e Entropia Condicional $H(C|K)$
- Normalized Mutual Information (NMI)
- Adjusted Rand Index

Medidas Internas

Abordagem não-supervisionada usando critérios derivados dos próprios dados.

- Coeficiente de Silhueta
- Índice Davies-Bouldin
- Compactação e separação

Medidas Relativas

Comparação direta entre diferentes clustering do mesmo algoritmo.

- Variação de parâmetros
- Análise comparativa
- Otimização iterativa

As medidas internas avaliam quão bem os clusters estão separados e quão compactos são internamente, enquanto medidas externas requerem labels verdadeiros para validação. Medidas relativas são úteis para fine-tuning de hiperparâmetros.

Exemplo de Medida Externa: Entropia Condicional $H(C|K)$

A **Entropia Condicional $H(C|K)$** quantifica a incerteza na classificação verdadeira dos dados dado o clustering obtido. Quanto menor o valor, melhor o clustering captura a estrutura real dos dados. É especialmente útil quando o *ground truth* está disponível, permitindo comparação objetiva entre diferentes algoritmos de agrupamento.

Clustering Probabilístico Baseado em Modelos

O clustering probabilístico adota uma perspectiva fundamentalmente diferente: clusters são categorias ocultas representadas por funções de densidade de probabilidade. Este framework matemático oferece maior flexibilidade e interpretabilidade.

Descobrir Categorias Ocultas

Identificar distribuições latentes que explicam a estrutura observada nos dados.

Representação Matemática

Cada cluster é uma função de densidade probabilística sobre o espaço de características.

Exemplo Aplicado

Segmentação de câmeras digitais: linha consumidor vs. linha profissional com densidades f_1 e f_2 .

Modelos de Mistura

Um modelo de mistura assume que os dados são gerados por uma combinação de múltiplas distribuições probabilísticas. Cada componente da mistura representa um cluster latente, e a estrutura dos dados emerge desse processo gerativo.

Premissa Fundamental

Cada objeto é gerado a partir de uma das k distribuições componentes do modelo de mistura.

Processo Gerativo

Seleciona-se o cluster de acordo com a probabilidade de mistura π_i ; em seguida, o objeto é gerado segundo a distribuição correspondente.

Tarefa de Inferência

Dado o conjunto de dados D , inferir os k clusters que maximizam a verossimilhança dos dados observados.

Clusters probabilísticos permitem modelar a incerteza inerente à atribuição de objetos, reconhecendo que alguns pontos podem pertencer parcialmente a múltiplos grupos.

Clustering Fuzzy (Soft Clustering)

Conceito

A teoria fuzzy permite pertinência parcial entre 0 e 1, ao contrário do **hard clustering**, que atribui cada objeto exclusivamente a um único cluster.

Hard Clustering

Pertinência $\in \{0, 1\}$
Exclusivo e binário

Fuzzy Clustering

Pertinência $\in [0, 1]$
Graus contínuos

Quando Usar

- Limites entre clusters naturalmente difusos
- Objetos com características de múltiplas categorias
- Dados com estrutura ambígua ou sobreposição

Algoritmo FCM (Fuzzy C-Means)

Generalização do K-Means com pertinências parciais. O parâmetro de **fuzziness** m controla o grau de sobreposição entre clusters ($m \rightarrow 1$: hard; m grande: muito difuso).

Vantagens

- **Captura incerteza**
- **Transições suaves entre clusters**
- **Robusto a outliers**
- **Matriz U rica em informação**

- ❏ A **matriz de pertinência U** armazena os graus de pertinência de cada objeto em relação a todos os clusters, revelando estruturas sobrepostas invisíveis ao hard clustering.

Algoritmo Fuzzy C-Means (FCM)

Fuzzy C-Means

Generalização do K-Means com pertinências parciais; cada ponto pertence a todos os clusters com graus entre 0 e 1.

- Parâmetro $m > 1$ controla fuzziness ($m = 2$ típico)
- Minimiza função objetivo ponderada por u_{ij}^m
- Converge para mínimo local
- Complexidade: $O(n \cdot c \cdot t)$ por iteração

Algoritmo Fuzzy C-Means (FCM)

Referência: Bezdek (1981)

ENTRADA: D (n objetos), c (n° de clusters), m (fuzziness, $m > 1$), ϵ (tolerância)

PRÉ-CONDIÇÃO: $c \geq 2$, $m > 1$

PASSO 1 — Inicialização

Inicializar matriz de pertinência U ($n \times c$) aleatoriamente

PARA CADA objeto i e cluster j :

$u_{ij} \in [0,1]$ e $\sum_j u_{ij} = 1$ # restrição de partição fuzzy

PASSO 2 — Atualização dos Centros

PARA CADA cluster j :

$v_j \leftarrow \sum_i (u_{ij}^m \cdot x_i) / \sum_i u_{ij}^m$ # centroide ponderado fuzzy

PASSO 3 — Atualização das Pertinências

PARA CADA objeto i e cluster j :

$u_{ij} \leftarrow 1 / \sum_k (\text{dist}(x_i, v_j) / \text{dist}(x_i, v_k))^{2/(m-1)}$

pertinência inversamente proporcional à distância relativa

PASSO 4 — Convergência

SE $\max |U_{\text{novo}} - U_{\text{ant}}| < \epsilon$: PARAR

SENÃO: $U \leftarrow U_{\text{novo}}$, voltar ao PASSO 2

SAÍDA: Centros $v_1, \dots, v_c$ e matriz U de pertinências

PÓS-CONDIÇÃO: $\sum_j u_{ij} = 1$ para todo objeto i ; minimiza $\sum_i \sum_j u_{ij}^m \cdot \text{dist}(x_i, v_j)^2$

Clustering Baseado em Modelos

Utiliza inferência estatística para descobrir a estrutura latente nos dados, maximizando a verossimilhança dos dados observados sob o modelo de mistura.

Componentes do Modelo

- **Parâmetros de mistura (π):** Probabilidades a priori de cada cluster
- **Parâmetros de distribuição (θ):** Caracterizam cada cluster (ex: μ e σ para Gaussianas)
- **Função de verossimilhança:** Probabilidade dos dados dado o modelo

📌 O algoritmo EM garante que a verossimilhança nunca diminui entre iterações, convergindo para um máximo local. Executar múltiplas vezes com inicializações diferentes ajuda a encontrar melhores soluções.

Modelo de Mistura Gaussiana Univariado

O Gaussian Mixture Model (GMM) é o modelo de mistura mais utilizado, assumindo que cada cluster segue uma distribuição normal (Gaussiana). Começamos com o caso univariado para ilustrar os conceitos fundamentais.

Componentes do Modelo

Cada cluster k é caracterizado por:

- μ_k : Média (centro do cluster)
- σ_k : Desvio padrão (dispersão)
- π_k : Peso da mistura (proporção)

A densidade de probabilidade para um ponto x é a soma ponderada das densidades Gaussianas individuais.

Interpretação intuitiva: Os dados são gerados ao selecionar aleatoriamente um dos k Gaussianos (com probabilidades π) e então amostrar um ponto daquela distribuição.

Estimação via EM

Passo E – Responsabilidades

$\gamma_{ik} = P(\text{cluster } k \mid x_i)$ via regra de Bayes: probabilidade posterior de cada ponto pertencer a cada cluster.

$$\gamma_{ik} = P(\text{cluster } k \mid x_i) = \frac{\pi_k \cdot f(x_i \mid \theta_k)}{\sum_l \pi_l \cdot f(x_i \mid \theta_l)}$$

Passo M – Médias

Média ponderada dos pontos pelas responsabilidades:

$$\mu_k = \frac{\sum_i \gamma_{ik} \cdot x_i}{\sum_i \gamma_{ik}}$$

Passo M – Variâncias

Variância ponderada em torno da nova média:

$$\sigma_k^2 = \frac{\sum_i \gamma_{ik} (x_i - \mu_k)^2}{\sum_i \gamma_{ik}}$$

Passo M – Pesos

Fração efetiva de pontos atribuída a cada cluster:

$$\pi_k = \frac{\sum_i \gamma_{ik}}{n}$$

0 Algoritmo EM (Expectation-Maximization)

Expectation-Maximization

Framework geral para estimação de máxima verossimilhança na presença de variáveis latentes.

- **Soft assignments:** cada ponto pertence a clusters com probabilidades
- **Converge para máximo local** da $\log L$ (log-verossimilhança)
- **Generaliza K-Means:** K-Means é EM com hard assignments

Algoritmo EM para Modelos de Mistura
Referência: Dempster, Laird & Rubin (1977)

ENTRADA: D (n objetos), k (n° de componentes), distribuição F

PRÉ-CONDIÇÃO: $k \geq 1$, F é família paramétrica (ex: Gaussiana)

PASSO 1 — Inicialização

Inicializar parâmetros $\theta = (\pi_1, \dots, \pi_k, \theta_1, \dots, \theta_k)$ aleatoriamente

$\pi_j \leftarrow 1/k$ para todo j # pesos de mistura uniformes

PASSO 2 — E-step (Expectation)

PARA CADA objeto x_i e cluster j :

$w_{ij} \leftarrow \pi_j \cdot f(x_i \mid \theta_j)$ # verossimilhança ponderada

$\sum_i \pi_i \cdot f(x_i \mid \theta_i)$

w_{ij} = probabilidade posterior de x_i pertencer ao cluster j

PASSO 3 — M-step (Maximization)

PARA CADA cluster j :

$n_j \leftarrow \sum_i w_{ij}$ # tamanho efetivo do cluster

$\pi_j \leftarrow n_j / n$ # atualiza peso de mistura

$\theta_j \leftarrow \operatorname{argmax}_{\theta} \sum_i w_{ij} \cdot \log f(x_i \mid \theta)$ # atualiza parâmetros

PASSO 4 — Convergência

SE $|\log L(\theta_{\text{novo}}) - \log L(\theta_{\text{ant}})| < \epsilon$: PARAR

SENÃO: $\theta \leftarrow \theta_{\text{novo}}$, voltar ao PASSO 2

SAÍDA: Parâmetros θ^* , pesos π_j^* , pertinências w_{ij}

PÓS-CONDIÇÃO: log-verossimilhança não decresce entre iterações

Modelos de Mistura: Vantagens e Limitações

Como toda técnica, modelos de mistura apresentam trade-offs importantes que devem ser considerados ao escolher esta abordagem para um problema específico de clustering.

Pontos Fortes

- **Generalidade:** Mais flexíveis que particionamento e clustering fuzzy tradicional
- **Parcimônia:** Clusters caracterizados por poucos parâmetros interpretáveis
- **Fundação estatística:** Satisfazem pressupostos de modelos gerativos
- **Incerteza quantificada:** Probabilidades de pertinência têm interpretação clara

Desafios

- **Ótimos locais:** Convergência para máximos locais (mitigado com múltiplas inicializações)
- **Custo computacional:** Alto quando k é grande ou dados são escassos
- **Requisito de dados:** Necessita datasets grandes para estimação confiável
- **Seleção de k :** Determinar número de clusters continua sendo desafiador

Recomendação prática: Modelos de mistura são ideais quando há justificativa teórica para distribuições Gaussianas e dados suficientes. Para problemas exploratórios com poucos dados, métodos mais simples podem ser preferíveis.

A Maldição da Dimensionalidade

Em espaços de alta dimensionalidade, os métodos tradicionais de clustering enfrentam obstáculos significativos que comprometem sua eficácia. O fenômeno conhecido como "maldição da dimensionalidade" manifesta-se através de múltiplos fatores que degradam o desempenho dos algoritmos.

Atributos irrelevantes ou altamente correlacionados introduzem ruído no processo de análise, mascarando padrões verdadeiros. A esparsidade dos dados aumenta exponencialmente com o número de dimensões, fazendo com que os pontos se tornem cada vez mais distantes uns dos outros.

O efeito de concentração de distâncias torna as medidas de similaridade praticamente inúteis, pois todos os pontos parecem igualmente distantes. Além disso, problemas de otimização tornam-se computacionalmente intratáveis à medida que a dimensionalidade cresce.

Esparsidade de Dados

Distribuição dispersa no espaço

Concentração de Distâncias

Medidas de similaridade perdem significado

Modelos de Clustering em Alta Dimensionalidade

A descoberta de clusters em dados de alta dimensionalidade baseia-se em um princípio fundamental: clusters significativos frequentemente se manifestam em subespaços específicos, envolvendo apenas um subconjunto dramaticamente menor de atributos em relação ao espaço completo.

Clusters em Subespaços

Estruturas ocultas reveladas através da análise de subconjuntos específicos de dimensões, onde padrões verdadeiros emergem claramente.

Subespaços Axis-Parallel

Identificação de clusters alinhados com os eixos originais dos atributos, simplificando interpretação e descoberta.

Subespaços Orientados Arbitrariamente

Detecção de estruturas em subespaços rotacionados, capturando padrões mais complexos e sofisticados nos dados.

📌 **Princípio Essencial:** O sucesso no clustering de alta dimensionalidade depende da capacidade de encontrar e explorar os subespaços corretos onde os clusters naturalmente existem.

Categorização de Métodos de Clustering em Alta Dimensionalidade

As técnicas para clustering em espaços de alta dimensionalidade podem ser organizadas em duas categorias principais, cada uma com suas próprias estratégias e abordagens especializadas.

Abordagens de Clustering

Identificam clusters em subespaços específicos através de três metodologias distintas:

- **Métodos de Subspace Clustering:** Encontram todos os clusters em todos os subespaços possíveis do espaço completo de dados
- **Métodos de Projected Clustering:** Particionam o conjunto de dados em subconjuntos não-sobrepostos, projetando-os em dimensões relevantes
- **Métodos de Bi-clustering:** Agrupam simultaneamente objetos e atributos, descobrindo estruturas bidimensionais

Métodos de Redução de Dimensionalidade

Transformam os dados de alta dimensionalidade em representações de menor dimensão, preservando as propriedades essenciais para clustering.

Estas técnicas incluem PCA (Principal Component Analysis), MDS (Multidimensional Scaling), e métodos de manifold learning que capturam a estrutura intrínseca dos dados.

Subspace Clustering: Métodos de Busca em Subespaços

Os métodos de subspace clustering exploram sistematicamente diferentes subespaços para descobrir clusters. Duas estratégias principais orientam essa busca, cada uma com suas vantagens computacionais e características específicas.

Abordagens Bottom-Up

Iniciam a busca em subespaços de baixa dimensionalidade e progressivamente exploram subespaços de maior dimensão apenas quando há evidências de que clusters podem existir nessas dimensões superiores.

- Utilizam técnicas sofisticadas de poda para reduzir drasticamente o número de subespaços de alta dimensão a serem examinados
- Baseiam-se no princípio de anti-monotonicidade: se não há cluster denso em um subespaço, não haverá em seus super-espaços
- **Exemplo clássico: CLIQUE** (Agrawal et al., 1998) - Pioneiro em clustering baseado em densidade para dados de alta dimensão

Abordagens Top-Down

Começam do espaço completo de atributos e recursivamente buscam subespaços menores, refinando progressivamente a seleção de dimensões relevantes.

- Efetivas principalmente quando a *suposição de localidade* é válida: o subespaço de um cluster pode ser determinado examinando a vizinhança local dos pontos
- Permitem descobrir diretamente os subespaços mais relevantes através de refinamento iterativo
- **Exemplo representativo: PROCLUS** (Aggarwal et al., 1999) - Método inspirado em k-medoid que projeta clusters em subespaços

Clustering de Grafos e Dados de Rede

Aplicações

Grafos Bipartidos

Relacionamentos entre clientes e produtos, autores e conferências

Motores de Busca

Grafos de click-through e estrutura da Web

Redes Sociais

Grafos de amizade e colaboração científica

Métodos de Clustering em Grafos

Cortes Mínimos

FastModularity (Clauset, Newman & Moore, 2004): Otimiza modularidade para detectar comunidades através de particionamento eficiente do grafo

Medidas de Similaridade

Distâncias Geodésicas

Comprimento do caminho mais curto entre nós no grafo

Random Walk

SimRank: similaridade baseada em probabilidade de caminhadas aleatórias

Clustering Baseado em Densidade

SCAN (Xu et al., KDD 2007): Structural Clustering Algorithm for Networks, identifica clusters, hubs e outliers em redes complexas

Referências Principais

Esta seleção de referências representa os pilares fundamentais para o estudo aprofundado de mineração de dados, cobrindo desde conceitos básicos até técnicas avançadas e aplicações contemporâneas.



1. **J. Han, J. Pei, and H. Tong**, *Data Mining: Concepts and Techniques*, 4th edition. Cambridge, MA: Morgan Kaufmann, 2022.
2. **G. M. James, D. Witten, T. Hastie, and R. Tibshirani**, *An Introduction to Statistical Learning: With Applications in R*. Springer Nature, 2021.
3. **S. Garcia, J. Luengo, and F. Herrera**, *Data Preprocessing in Data Mining*. Springer, 2014.
4. **C. M. Bishop and H. Bishop**, *Deep Learning: Foundations and Concepts*. Springer Nature, 2023.