

Detecção de Outliers: métodos, contexto e falsos alarmes

O Que São Outliers?

Um **outlier** é um objeto de dados que se desvia significativamente dos objetos normais, como se tivesse sido gerado por um mecanismo diferente. Esses pontos anômalos representam comportamentos inesperados que merecem atenção especial na análise de dados.

Por exemplo, uma compra incomum no cartão de crédito pode indicar fraude, enquanto leituras anormais de sensores podem revelar falhas em equipamentos industriais. A identificação correta de outliers é crucial para detectar eventos raros, falhas sistêmicas ou atividades fraudulentas.

Aplicações Práticas

- Detecção de fraude em cartões de crédito
- Identificação de fraude em telecomunicações
- Segmentação avançada de clientes
- Análise médica e diagnóstico

Outliers versus Ruído

Ruído

Erro aleatório ou variância em uma variável medida. Não é interessante para análise de dados, incluindo detecção de outliers.

Exemplo: Um almoço maior em um dia ou uma xícara extra de café em relação ao usual.

Outliers

São interessantes porque suspeita-se que não foram gerados pelo mesmo mecanismo que o restante dos dados.

Exemplo: Faça várias suposições sobre o restante dos dados e mostre que os outliers detectados violam essas suposições significativamente.

❏ **Critério de Explicabilidade:** Outliers devem ser explicáveis em termos de um mecanismo gerador diferente, enquanto o ruído é simplesmente variação aleatória sem significado analítico.

Detecção de Outliers versus Detecção de Novidades

Detecção de Outliers

Identifica objetos que desviam significativamente do padrão estabelecido dos dados existentes. O foco está em encontrar anomalias que não se encaixam no modelo atual.

- Objetos permanecem classificados como outliers
- Não há atualização do modelo base
- Útil para detecção de fraudes e erros

Exemplo prático: Ao monitorar um site de mídia social onde novo conteúdo está sempre chegando, a detecção de novidades pode identificar novos tópicos e tendências de maneira oportuna. Tópicos novos podem inicialmente aparecer como outliers, mas são rapidamente incorporados ao modelo de normalidade.

Detecção de Novidades

Identifica novos padrões emergentes que inicialmente aparecem como outliers. Uma vez confirmadas, as novidades são incorporadas ao modelo para que instâncias futuras não sejam tratadas como outliers.

- Novidades confirmadas atualizam o modelo
- Adaptação contínua aos novos padrões
- Ideal para monitoramento de tendências

Tipos de Outliers

A classificação de outliers é fundamental para escolher a abordagem de detecção adequada. Cada tipo possui características distintas e requer técnicas específicas de identificação.

Outliers Globais

Objetos que estão distantes da maioria dos dados, considerando todo o conjunto de dados sem contexto adicional.

Outliers Contextuais

Objetos anormais apenas em um contexto específico, mas normais em outros contextos.

Outliers Coletivos

Uma coleção de objetos relacionados que é anômala como um todo, mesmo que objetos individuais pareçam normais.

Outliers Globais

Outliers globais são objetos que se desviam significativamente do restante dos dados quando consideramos o conjunto de dados como um todo. Eles representam o tipo mais simples e intuitivo de anomalia.

Características Principais

- Podem ser detectados sem considerar contexto adicional
- Desvio significativo das medidas estatísticas centrais
- Facilmente identificáveis em visualizações de dados
- Independentes de variáveis temporais ou espaciais

📄 **Exemplo ilustrativo:** Uma transação de cartão de crédito incomumente grande em comparação com o padrão típico de gastos de um cliente representa um outlier global claro.

Outliers Contextuais

Um outlier contextual é um objeto que se torna anômalo apenas dentro de um contexto específico. A mesma observação pode ser perfeitamente normal em um contexto e completamente anormal em outro, tornando a detecção dependente da compreensão do ambiente em que o dado foi gerado.



Exemplo Clássico

Uma temperatura de 30°C pode ser completamente normal durante o verão, mas seria altamente anômala e preocupante se ocorresse no inverno.

Ideia Central

O mesmo objeto pode ser normal em um contexto e anormal em outro. A detecção requer análise do contexto para determinar se o comportamento é esperado ou não.

Complexidade Adicional

Requer identificação de atributos contextuais relevantes e modelagem de comportamentos normais específicos para cada contexto possível.

Atributos Contextuais versus Comportamentais

Para detectar outliers contextuais de forma eficaz, é essencial distinguir entre dois tipos fundamentais de atributos que caracterizam os dados.

Atributos Contextuais

Definem o contexto no qual a observação ocorre. São as dimensões que determinam "onde" ou "quando" o comportamento acontece.

Exemplos: tempo, localização geográfica, dia da semana, estação do ano

Atributos Comportamentais

Descrevem o comportamento observado do objeto. São as medidas que capturamos e analisamos para detectar anomalias.

Exemplos: valor da transação, temperatura, volume de tráfego de rede, frequência cardíaca

Outliers Coletivos

Em outliers coletivos, objetos individuais podem parecer completamente normais quando analisados isoladamente. No entanto, quando considerados como uma coleção ou sequência, o conjunto revela um padrão anômalo que indica comportamento suspeito ou problemático.

Objetos Individuais Normais

Cada pacote de rede ou transação, quando examinado individualmente, apresenta características dentro dos parâmetros esperados e não levanta suspeitas.

Padrão Coletivo Anômalo

A sequência, frequência ou combinação específica desses objetos normais forma um padrão que é estatisticamente improvável ou inconsistente com comportamentos legítimos.

Exemplo de Intrusão

Uma sequência de pacotes de rede que individualmente parecem normais, mas juntos indicam uma tentativa de intrusão ou ataque coordenado ao sistema.

Aplicações de Outliers Coletivos

A detecção de outliers coletivos é crucial em domínios onde padrões sequenciais revelam anomalias invisíveis na análise de pontos individuais.

Detecção de Intrusão

Análise de sequências de atividades de rede que coletivamente indicam tentativas de invasão.

Padrões de Mau Funcionamento de Sensores

Leituras dentro dos limites individuais que coletivamente indicam degradação ou falha iminente.

Padrões de Fraude ao Longo do Tempo

Múltiplas transações aparentemente legítimas que juntas revelam atividade suspeita coordenada.

Subsequências Anormais em Séries Temporais

Combinação de valores normais que forma padrões desviantes do comportamento esperado do sistema.

Comparação Entre Múltiplos Tipos de Outliers

Coexistência de Tipos

Um dataset pode conter múltiplos tipos de outliers simultaneamente, cada um exigindo abordagens específicas.

Complexidade relativa dos métodos

Outliers Globais

Detecção simples — sem necessidade de contexto.

Sobreposição de Categorias

Um mesmo objeto pode pertencer a mais de um tipo dependendo da perspectiva de análise.

Outliers Contextuais

Complexidade média — exige definição de atributos contextuais.

Aplicações Variadas

Cada tipo é útil para propósitos distintos, de detecção de fraude a identificação de tendências emergentes.

Outliers Coletivos

Maior complexidade — requer modelagem de relações entre objetos.

Desafios na Detecção de Outliers

A detecção de outliers é inerentemente difícil devido a características dos dados do mundo real que complicam a identificação precisa de anomalias.

Falta de Dados Rotulados

Outliers são raros e frequentemente desconhecidos antecipadamente, dificultando o treinamento supervisionado.

Ruído e Incerteza

Erros aleatórios podem obscurecer outliers verdadeiros ou gerar falsos alarmes, imitando anomalias genuínas.

Dependência de Contexto

Um objeto pode ser normal globalmente, mas anômalo sob um contexto específico de usuário ou horário.

Alta Dimensionalidade

Em espaços de alta dimensão, medidas de distância tornam-se menos discriminativas (maldição da dimensionalidade).

Distribuições Evolutivas

O comportamento normal muda ao longo do tempo (concept drift), exigindo adaptação contínua dos modelos.

Categorias de Métodos de Detecção de Outliers

Cinco abordagens principais, cada uma com suposições e técnicas distintas.

Métodos Baseados em Estatística

Assumem uma distribuição de probabilidade e identificam objetos que se desviam significativamente usando testes estatísticos.

Métodos Baseados em Distância

Detectam outliers pela distância a objetos vizinhos usando métricas como euclidiana ou Mahalanobis.

Métodos Baseados em Densidade

Identificam objetos em regiões de densidade muito menor que seus vizinhos, como o algoritmo LOF.

Métodos Baseados em Clustering

Tratam como outliers objetos sem cluster ou em clusters muito pequenos, usando K-means, DBSCAN ou clustering hierárquico.

Métodos Baseados em Classificação

Aprendem uma fronteira de decisão para separar normais de anomalias usando One-Class SVM ou redes neurais.

Ideia Geral dos Métodos Estatísticos

A ideia fundamental dos métodos estatísticos é aprender um modelo generativo ajustado aos dados e identificar objetos em regiões de baixa probabilidade como outliers.

Métodos Paramétricos


Assumem que os objetos de dados normais são gerados por uma distribuição paramétrica com um número finito de parâmetros Θ . A função de densidade de probabilidade $f(x, \Theta)$ fornece a probabilidade de que o objeto x seja gerado pela distribuição. Quanto menor este valor, maior a probabilidade de x ser um outlier.

Métodos Não-Paramétricos

Tentam determinar o modelo diretamente a partir dos dados de entrada, sem assumir uma forma específica de distribuição. Esta flexibilidade permite capturar padrões mais complexos nos dados, mas pode exigir mais dados para estimativas confiáveis.

Visualização com Boxplot

O boxplot é uma ferramenta visual poderosa que utiliza um resumo de cinco números para identificar outliers de forma intuitiva. Esta técnica estatística clássica fornece uma representação gráfica da distribuição dos dados e destaca valores anômalos.



Resumo de Cinco Números

- Menor valor não-outlier (Min)
- Quartil inferior (Q1)
- Mediana (Q2)
- Quartil superior (Q3)
- Maior valor não-outlier (Max)

Intervalo Interquartil (IQR)

Definido como $Q3 - Q1$, representa o intervalo contendo os 50% centrais dos dados

Critério de Outlier

Qualquer objeto mais de $1.5 \times \text{IQR}$ abaixo de Q1 ou acima de Q3 é tratado como outlier

Cobertura Estatística

A região entre $Q1 - 1.5 \times \text{IQR}$ e $Q3 + 1.5 \times \text{IQR}$ contém 99,3% dos objetos normais

Teste de Grubbs

Método estatístico formal para detectar outliers univariados em dados com distribuição aproximadamente normal, identificando um outlier por vez.

 **Nota Importante:** O teste de Grubbs assume que os dados seguem uma distribuição normal e é projetado para detectar apenas um outlier por vez. Para múltiplos outliers, o teste deve ser aplicado iterativamente.

Algoritmo: Teste de Grubbs (Detecção de Outlier Univariado)
Referência: Grubbs (1969)

ENTRADA: X (vetor de n observações), α (nível de significância)

PRÉ-CONDIÇÃO: X segue distribuição aproximadamente normal

PASSO 1 — Calcular Estatísticas Descritivas

$\bar{x} \leftarrow \text{média}(X)$

$s \leftarrow \text{desvio_padrão}(X)$

PASSO 2 — Calcular Estatística de Grubbs

PARA CADA x_i em X :

$G_i \leftarrow |x_i - \bar{x}| / s$

$G \leftarrow \max(G_i)$ # maior desvio normalizado

$x_{\text{cand}} \leftarrow \text{argmax}(G_i)$ # candidato a outlier

PASSO 3 — Valor Crítico

$t_{\text{crit}} \leftarrow \text{quantil_t}(\alpha/(2n), n-2)$ # distribuição t de Student

$G_{\text{crit}} \leftarrow ((n-1)/\sqrt{n}) \cdot \sqrt{(t_{\text{crit}}^2 / (n-2 + t_{\text{crit}}^2))}$

PASSO 4 — Decisão

SE $G > G_{\text{crit}}$:

MARCAR x_{cand} como outlier

$X \leftarrow X \setminus \{x_{\text{cand}}\}$ # remover e repetir se necessário

SENÃO:

RETORNAR "Nenhum outlier detectado"

SAÍDA: conjunto de outliers identificados

PÓS-CONDIÇÃO: cada outlier viola H_0 com significância α

Detecção de Outliers Multivariados

Um ponto pode não ser outlier em nenhuma dimensão individual, mas ser anômalo quando todas as dimensões são consideradas juntas.

Distância de Mahalanobis

Mede a distância ao centro considerando a covariância entre variáveis.

Abordagem da Matriz de Covariância

Captura relações lineares entre variáveis para identificar outliers.

Elipsóides de Confiança

Define regiões multidimensionais; pontos externos são outliers.

Algoritmo: Detecção Multivariada via χ^2 (Mahalanobis)
Referência: Barnett & Lewis (1994)

ENTRADA: X (matriz $n \times p$ de observações), α (nível de significância)

PRÉ-CONDIÇÃO: X segue distribuição normal multivariada

PASSO 1 — Estimar Parâmetros

$\mu \leftarrow \text{média}(X)$ # vetor de médias (p-dimensional)

$\Sigma \leftarrow \text{covariância}(X)$ # matriz de covariância $p \times p$

PASSO 2 — Calcular Distância de Mahalanobis

PARA CADA observação x_i em X :

$D^2(x_i) \leftarrow (x_i - \mu)^T \cdot \Sigma^{-1} \cdot (x_i - \mu)$

D^2 segue distribuição χ^2 com p graus de liberdade

PASSO 3 — Definir Valor Crítico

$\chi^2_{\text{crit}} \leftarrow \text{quantil_chi2}(1 - \alpha, p)$

tipicamente $\alpha = 0.05$ ou 0.01

PASSO 4 — Classificação

PARA CADA observação x_i em X :

SE $D^2(x_i) > \chi^2_{\text{crit}}$:

MARCAR x_i como outlier multivariado

SENÃO:

MARCAR x_i como normal

SAÍDA: conjunto de outliers multivariados identificados

PÓS-CONDIÇÃO: outliers violam hipótese de normalidade com nível α

Prós e Contras dos Métodos Estatísticos

Vantagens

Base matemática sólida com intervalos de confiança interpretáveis. Resultados quantificáveis e validáveis teoricamente.

Desafios Dimensionais

A "maldição da dimensionalidade" compromete a estimação de parâmetros. Testes estatísticos perdem eficácia em espaços de alta dimensão.


Considerações Computacionais

Modelos paramétricos simples são geralmente eficientes. Métodos não-paramétricos podem ser intensivos para grandes volumes de dados.

Métodos Baseados em Proximidade

Um objeto é considerado um outlier se seus vizinhos mais próximos estão distantes — ou seja, se a proximidade do objeto desvia significativamente da maioria dos outros objetos no mesmo conjunto de dados.

Exemplo Ilustrativo



Modelando a proximidade com os **3 vizinhos mais próximos**: objetos na região **R** são substancialmente diferentes dos demais — portanto, são outliers.

Métodos Baseados em Distância


Um objeto é considerado outlier se sua vizinhança **não possui pontos suficientes** dentro de um raio r ou possui menos que k vizinhos mínimos. Foca na ausência de pontos próximos no espaço de dados.

Métodos Baseados em Densidade

Um objeto é identificado como outlier se sua **densidade local é significativamente menor** que a densidade de seus vizinhos. Preferível quando os clusters apresentam densidades variadas, pois captura anomalias relativas ao contexto local.

Detecção Baseada em Distância

Outliers estão isolados de seus vizinhos — formalizados por definições matemáticas precisas sobre raio e contagem de pontos próximos.



📄 **Complexidade Computacional:** A complexidade ingênua é $O(n^2)$ onde n é o número de pontos. Estruturas de dados espaciais como kd-trees ou ball-trees podem reduzir significativamente este custo para conjuntos de dados de dimensionalidade moderada.

Algoritmo: Detecção de Outliers por Distância (DB-Outlier)

Referência: Knorr & Ng (1998)

ENTRADA: D (conjunto de n pontos), r (raio), π (fração mínima de vizinhos)

PRÉ-CONDIÇÃO: métrica de distância $\text{dist}()$ definida sobre D

PASSO 1 — Parâmetros

$\text{MinPts} \leftarrow \pi \cdot n$ # nº mínimo de vizinhos esperado

PASSO 2 — Para cada ponto

PARA CADA ponto p em D :

 vizinhos $\leftarrow 0$

 PARA CADA ponto q em D , $q \neq p$:

 SE $\text{dist}(p, q) \leq r$:

 vizinhos $\leftarrow \text{vizinhos} + 1$

PASSO 3 — Classificação

 SE vizinhos $< \text{MinPts}$:

 MARCAR p como DB-Outlier(r, π)

 SENÃO:

 MARCAR p como normal

PASSO 4 — Otimização (opcional)


 Usar kd-tree ou ball-tree para reduzir complexidade de $O(n^2)$ para $O(n \log n)$

SAÍDA: conjunto de DB-Outliers identificados

PÓS-CONDIÇÃO: cada outlier tem $< \pi \cdot n$ vizinhos no raio r

Detecção de Outliers Baseada em Densidade

Os métodos baseados em densidade capturam a intuição de que outliers residem em regiões de baixa densidade em comparação com seus vizinhos. Esta abordagem é particularmente poderosa quando os dados contêm clusters de densidades variadas, onde métodos simples baseados em distância podem falhar.



Conceito de Densidade Local

A densidade local de um ponto é estimada com base na densidade de seus vizinhos mais próximos. Pontos em regiões esparsas têm baixa densidade local, enquanto pontos em clusters densos têm alta densidade local.

Densidade de Raio

Calcula o número de pontos dentro de um raio especificado. Simples de computar, mas sensível à escolha do raio.

Densidade k-NN


Usa a distância ao k-ésimo vizinho mais próximo como estimativa inversa da densidade. Adapta-se melhor a variações locais de densidade.

Densidade Relativa

Compara a densidade local de um ponto com a densidade de seus vizinhos, permitindo detectar outliers em clusters de diferentes densidades.

Local Outlier Factor (LOF)

Um valor LOF próximo de 1 indica que o ponto tem densidade similar aos vizinhos; valores significativamente maiores que 1 indicam outliers.



Conceitos Fundamentais

- **k-distance:** Distância do ponto ao seu k-ésimo vizinho mais próximo
- **Reachability distance:** Máximo entre k-distance do vizinho e distância real
- **LRD (Local Reachability Density):** Inverso da média das reachability distances
- **LOF:** Razão entre LRD médio dos vizinhos e LRD do ponto

Algoritmo: Local Outlier Factor (LOF)

Referência: Breunig et al. (2000)

ENTRADA: D (conjunto de pontos), k (nº de vizinhos)

PRÉ-CONDIÇÃO: $k < |D|$, métrica **dist()** definida

PASSO 1 — k-Vizinhos e k-distance

PARA CADA ponto p em D:

N_k(p) $\leftarrow$ k vizinhos mais próximos de p

k-dist(p) $\leftarrow$ **dist**(p, k-ésimo vizinho)

PASSO 2 — Reachability Distance

PARA CADA p e o em **N_k(p)**:

reach-dist_k(p, o) $\leftarrow$ **max**(**k-dist**(o), **dist**(p, o))

PASSO 3 — Local Reachability Density (LRD)

PARA CADA ponto p em D:

LRD_k(p) $\leftarrow |N_k(p)| / \sum \text{reach-dist}_k(p, o)$

para o em **N_k(p)**

PASSO 4 — LOF Score

PARA CADA ponto p em D:

LOF_k(p) $\leftarrow (\sum \text{LRD}_k(o) / \text{LRD}_k(p)) / |N_k(p)|$

para o em **N_k(p)**

SE **LOF_k(p)** $\gg 1$:


MARCAR p como outlier local

SAÍDA: score LOF para cada ponto em D

PÓS-CONDIÇÃO: $\text{LOF} \approx 1 \rightarrow$ normal; $\text{LOF} \gg 1 \rightarrow$ outlier

Detecção Baseada em Clustering

Pontos que não pertencem a nenhum cluster existente ou que formam clusters anômalos — pequenos, esparsos ou muito distantes dos demais — são considerados outliers.



Pontos Isolados

Pontos individuais que não se ajustam a nenhum cluster existente

Clusters Anômalos

Clusters inteiros que são pequenos, esparsos ou muito distantes dos demais

Algoritmo: Detecção de Outliers por Clustering (Largura Fixa)

Referência: Han, Pei & Tong (2022)

ENTRADA: D (conjunto de pontos), r (raio do cluster),
 θ_size (tamanho mínimo), θ_dist (distância mínima)

PRÉ-CONDIÇÃO: métrica $dist()$ definida sobre D

PASSO 1 — Construção dos Clusters

$C \leftarrow \emptyset$ # conjunto de clusters

PARA CADA ponto p em D :

$c_prox \leftarrow$ cluster mais próximo de p em C

SE $dist(p, centro(c_prox)) \leq r$:

ADICIONAR p a c_prox

ATUALIZAR $centro(c_prox)$

SENÃO:

CRIAR novo cluster $c = \{p\}$

$C \leftarrow C \cup \{c\}$

PASSO 2 — Identificar Outliers por Isolamento

PARA CADA ponto p em D :

SE p não pertence a nenhum cluster em C :

MARCAR p como outlier (ponto isolado)

PASSO 3 — Identificar Clusters Anômalos

PARA CADA cluster c em C :

SE $|c| < \theta_size$ OU

$dist(c, C \setminus \{c\}) > \theta_dist$:

MARCAR todos os pontos de c como outliers

SAÍDA: conjunto de outliers identificados

PÓS-CONDIÇÃO: outliers são pontos isolados ou em clusters anômalos

Análise Crítica: Forças e Fraquezas dos Métodos Baseados em Clustering

Forças

- **Aprendizado não supervisionado:** Detecta outliers sem necessidade de dados rotulados
- **Versatilidade:** Funciona para diversos tipos de dados estruturados e não estruturados
- **Eficiência após treinamento:** Clusters servem como resumos dos dados, permitindo comparação rápida de novos objetos
- **Velocidade operacional:** Após obtenção dos clusters, determinar se um objeto é outlier é computacionalmente rápido


Fraquezas

- **Dependência do método:** Eficácia depende altamente do algoritmo de clustering usado, que pode não estar otimizado para detecção de outliers
- **Custo computacional inicial:** Requer primeiro encontrar os clusters, o que pode ser custoso em grandes volumes de dados
- **Sensibilidade a parâmetros:** Escolha inadequada de parâmetros pode comprometer a qualidade da detecção

Método Baseado em Classificação: Modelo de Classe Única

Modelo de Classe Única (One-Class SVM)

O modelo aprende a **fronteira da classe normal** a partir de exemplos normais. Qualquer ponto fora dessa fronteira de decisão é declarado como **outlier**.



❑ **Vantagem Principal:** Capaz de detectar novos outliers que podem não aparecer próximos a objetos anômalos no conjunto de treinamento, oferecendo maior robustez e capacidade de generalização.

Algoritmo: One-Class SVM (Detecção por Classe Única)

Referência: Schölkopf et al. (2001)

ENTRADA: X_{train} (dados normais), v (fração esperada de outliers), K (função kernel), novos pontos X_{test}
PRÉ-CONDIÇÃO: X_{train} contém apenas exemplos normais

PASSO 1 — Mapeamento para Espaço de Features

PARA CADA x_i em X_{train} :

$\phi(x_i) \leftarrow K(x_i, \cdot)$ # mapear via kernel (ex: RBF)

PASSO 2 — Otimização (encontrar hiperplano de separação)

Maximizar: $\rho - (1/vn) \sum \xi_i$

Sujeito a:

$w \cdot \phi(x_i) \geq \rho - \xi_i$ # pontos normais dentro da fronteira

$\xi_i \geq 0$ # folgas não-negativas

PASSO 3 — Função de Decisão

$f(x) \leftarrow \text{sign}(w \cdot \phi(x) - \rho)$

$f(x) = +1 \rightarrow$ ponto normal (dentro da fronteira)

$f(x) = -1 \rightarrow$ outlier (fora da fronteira)

PASSO 4 — Classificação de Novos Pontos

PARA CADA ponto x em X_{test} :

SE $f(x) = -1$:

MARCAR x como outlier

SENÃO:

MARCAR x como normal

SAÍDA: classificação de cada ponto em X_{test}

PÓS-CONDIÇÃO: $\sim v \cdot n$ pontos de treino ficam fora da fronteira

Método Baseado em Classificação: Aprendizado Semi-Supervisionado

Forças

Velocidade de detecção: Uma vez treinado o modelo, a detecção de outliers é computacionalmente rápida e eficiente, permitindo análise em tempo real de novos dados.

Escalabilidade: Adequado para aplicações que requerem processamento contínuo de grandes volumes de dados após a fase de treinamento.

Gargalos

Dependência de dados de treinamento: A qualidade da detecção depende fortemente da disponibilidade e qualidade do conjunto de treinamento.

Desafio prático: Frequentemente é difícil obter dados de treinamento representativos e de alta qualidade, especialmente dados rotulados de outliers raros.

Viés de amostragem: Conjuntos de treinamento desbalanceados podem levar a modelos que não generalizam bem para novos tipos de anomalias.

☐ Ideal quando há abundância de dados normais mas escassez de exemplos rotulados de outliers.

Referências Principais

Esta seleção de referências representa os pilares fundamentais para o estudo aprofundado de mineração de dados, cobrindo desde conceitos básicos até técnicas avançadas e aplicações contemporâneas.



1. **J. Han, J. Pei, and H. Tong**, *Data Mining: Concepts and Techniques*, 4th edition. Cambridge, MA: Morgan Kaufmann, 2022.
2. **G. M. James, D. Witten, T. Hastie, and R. Tibshirani**, *An Introduction to Statistical Learning: With Applications in R*. Springer Nature, 2021.
3. **S. Garcia, J. Luengo, and F. Herrera**, *Data Preprocessing in Data Mining*. Springer, 2014.
4. **C. M. Bishop and H. Bishop**, *Deep Learning: Foundations and Concepts*. Springer Nature, 2023.